

דוח סופי

פרויקט גמר



בניית מערכת ניהול מלאי
חכמה מבוססת למידת מכונה

מנחה אקדמי : מר אברהם מורדוך
מגיש : עאדל קאלותי , ת.ז : 212339188
מוסד אקדמי : עזריאלי מכללה אקדמית להנדסה
המחלקה להנדסת תעשייה וניהול

הצהרה

העבודה נעשתה על ידי הסטודנט עאדל קאלותי,

בהנחיית מר אברהם מורדוך ,

עזריאלי מכללה אקדמית להנדסה ירושלים,

המחלקה להנדסת תעשייה וניהול.

החיבור מציג את עבודתנו האישית

ומהווה חלק מהדרישות לקבלת תואר ראשון בהנדסה.

כל טקסט ו/או תוצאה המבוססים על עבודות מחקר אחרות,

מתועדים בציון המקור המדעי.

תקציר

הפרויקט עוסק בפיתוח מערכת מתקדמת לניהול מלאי, המבוססת על תוכנת Excel ומשלבת מודלים אוטומטיים ומתקדמים טכנולוגית לחיזוי ביקוש. מטרת המערכת היא לצמצם את זמני חוסרי המלאי, להגדיל את רמת השירות ללקוח, ולשפר את תהליך קבלת ההחלטות בניהול מלאי בשטח. המערכת שילבה בין מודל (EOQ), מודל Continuous Review ומודלים סטטיסטיים מתקדמים כגון (Random Forest), במטרה לשפר את איכות התחזיות ולאפשר הזמנות מדויקות ונכונות בהתאם לדפוסי הביקוש בפועל של המוצרים.

המערכת נבחנה באמצעות סימולציה שכללה למעלה מ-1,000 תחזיות עבור 800 מוצרים. הניסוי כלל השוואה בין שלושת המודלים הקלאסיים לבין המודל החכם שפותח בפרויקט, והתקבלו תובנות משמעותיות לגבי ההתאמה של כל מודל לסוג מוצר אחר. לדוגמה, מודל Continuous Review התאים למוצרים בסיסיים בעלי יציבות יחסית, אך הציג חוסרים תכופים במוצרים חריגים. לעומתו, המודל החכם שהתבסס על אלגוריתם Random Forest הצליח לזהות מגמות חריגות ולחזות עליה חריגה בביקוש מבעוד מועד תוצאה שהביאה לצמצום משמעותי של חוסרי מלאי ועלות אחזקת מלאי.

ייחודיות הפרויקט נבעה מהשילוב שבין מתודולוגיה חישובית מתקדמת לבין הבנה מערכתית של הסביבה העסקית. המערכת לא רק הציגה תחזיות טובות יותר אלא גם נבנתה בצורה המאפשרת יישום פשוט בחנויות, ללא צורך בידע קודם בתכנות. הוספת משתנים כגון סופי שבוע, מגמות חריגות, ועונות השנה שיפרה את הדיוק במידה ניכרת. השילוב עם מערכת ההזמנות בפועל (Excel) איפשר תרגום התחזיות לפעולה ממשית וליצירת תהליך אוטומטי להזמנה מספקים.

השלב החשוב ביותר בפרויקט היה שלב היישום המלא בשטח. המערכת הוטמעה במחלקת חומרי הניקוי בסניף קשת טעמים ונבדקה לאורך חודשיים וחצי: חודש לספירת מלאי ואיסוף מידע, וחודש וחצי לבדיקת התחזיות והזמנות בפועל לפי המודל. היישום אפשר לבצע התאמות למציאות היומיומית בחנות – החל מהתנהגות סוכנים, דרך זמינות הספקים ועד למבצעים חריגים. התוצאות היו חד משמעיות: צמצום משמעותי בימי מלאי אפס, ירידה של מאות שקלים בעלות החוסרים, שיפור בדיוק התחזית, וצמצום בכמות ההזמנות מול ספקים.

מעבר לתועלות המספריות, המערכת תרמה גם לשיפור ביעילות התפעולית של המחלקה. סידור הזמנות לפי תחזית קבועה וניתוח יומי של הביקוש בפועל מול התחזיות, אפשרו התאמה טובה יותר של המלאי ולתכנון חכם לאורך זמן. המערכת גם תומכת בהחלטות ניהוליות עתידיות, באמצעות ניתוח שוטף של סטיות חיזוי, ומאפשרת גמישות רבה במעבר בין מודלים לפי סוג המוצר.

הפרויקט מדגים את הפוטנציאל של שילוב בינה מלאכותית, אקסל ויישום בשטח ככלי משמעותי לשיפור תהליכים ארגוניים. באמצעות פיתוח הדרגתי, ניתוח ביקוש מדויק ויישום אמיתי – נוצר כלי שלם, פשוט להפעלה ומבוסס מדדים ברורים, שניתן לשכפול ולהרחיב ברשתות נוספות. המודל מספק פתרון גמיש, מדויק וניתן להתאמה לשינויים בשוק – ומאפשר מעבר מניהול ריאקטיבי לניהול פרואקטיבי של מלאי.

תוכן עניינים

1.	מבוא	6
2.	מטרות הפרויקט	7
2.1	מטרות ממוקדות	7
2.2	מדדים ויעדים	8
3.	סקר ספרות	9
3.1	מבוא לסקר הספרות	9
3.2	מודל Economic Order Quantity (EOQ)	10
3.3	מודל Continuous Review (Q,R)	11
3.4	למידת מכונה וסוגיה	12
3.5	רגרסיה לינארית	13
3.6	סקר ספרותי Random Forest	14
4.	מתודולוגיה (שיטת SDLC)	15
5.	חקר מצב קיים	17
5.1	חקר מערכות המתחרים	17
5.2	סימולציה לשיטות קיימות	18
5.3	ניתוח תוצאות הסימולציה	20
6.	תוצאות	23
6.1	בניית המודל החדש - גרסה ראשונית (Pilot Phase)	23
6.2	תוצאות ראשוניות למודל החדש	24
6.3	ניתוח תוצאות הסימולציה עם המודל החדש	24
6.4	בניית המודל החדש - גרסה 2	26
6.5	תוצאות מעבר בין גרסה 1 ל- גרסה 2 של המודל	27
7.	בניית המערכת	28
8.	יישום הפרויקט	32
8.1	סביבת יישום הפרויקט	32
8.2	איך זהינו הבעיה בשטח?	33
8.3	תהליך איסוף נתונים + יישום המודל	33
8.4	תוצאות מדדי ההצלחה הכמותיים	34
9.	מסקנות והמלצות	35
10.	בעיות בעבודה	37
11.	הצעה לפרויקט המשך	38
12.	מקורות	39
13.	נספחים	40

תוכן עניינים לגרפים, טבלאות, תמונות:

1. אובייקט 1 שלבי שיטת SDLC 15
2. אובייקט 2 טבלת השוואת עלויות כוללת 17
3. אובייקט 3 סימולציה רמות מלאי 18
4. אובייקט 4 טבלת תוצאות הסימולציה 18
5. אובייקט 5 מדד ביצוע KPI לסימולציה 19
6. אובייקט 6 טבלת נתוני סימולציות 20
7. אובייקט 7 גרף מספר ההזמנות שבוצעו בכל מודל 20
8. אובייקט 8 גרף מספר האירועים והימים בהם המלאי אזל לחלוטין 21
9. אובייקט 9 גרף עלויות ניהול מלאי בשלושת המודלים 21
10. אובייקט 10 גרף העלות הכוללת 22
11. אובייקט 11 טבלת נתוני סימולציות מודלים כולל המודל החדש 24
12. אובייקט 12 גרף מספר ההזמנות של ארבעה מודלים 24
13. אובייקט 13 גרף מספר אירועי וימי אפס מלאי 25
14. אובייקט 14 גרף הרכב העלויות של ארבעת המודלים 25
15. אובייקט 15 טבלת נתוני ביקוש יומי 26
16. אובייקט 16 מדדי דיוק גרסה ראשונה 27
17. אובייקט 17 מדדי דיוק גרסה שנייה 27
18. אובייקט 18 מערכת ניהול מלאי גליון ראשי 28
19. אובייקט 19 מערכת ניהול מלאי גליון מלאי במחסן 28
20. אובייקט 20 השוואה בין תחזית קבועה 30
21. אובייקט 21 השוואת תחזית בסיסית חכמה 30
22. אובייקט 22 תחזית משולבת מתקדמת ML 31
23. אובייקט 23 מקום היישום בפועל 32
24. אובייקט 24 אירועים של מלאי אפס 33
25. אובייקט 25 תוצאות מדדי ההצלחה הכמותיים 34

מבוא

ניהול מלאי הוא תחום מרכזי וקריטי בפעילות התפעולית של ארגונים קמעונאיים, המשפיע ישירות על יכולתם לספק מוצרים ללקוחותיהם באופן מדויק, רציף ויעיל. תחום זה מתמודד עם אתגרים כמו חוסר ודאות בביקוש, חוסרים במלאי, עלויות הזמנה ואחסון, הצורך בתחזיות מדויקות והיכולת לקבל החלטות מיידיות על בסיס מידע חלקי. הפרויקט הנוכחי התמקד בפיתוח מערכת מתקדמת לניהול מלאי, המתבססת על כלים חישוביים מתקדמים ומודלים סטטיסטיים, מתוך מטרה להציע פתרון חכם ואפקטיבי לבעיית ניהול המלאי הקלאסית.

הבעיה המרכזית שהובילה את הפרויקט הייתה חוסר הוודאות והקושי בניהול מלאי בתנאים שבהם הביקוש משתנה תדיר, וישנה מגבלה של שטח אחסון, זמינות מוצרים ותנודות בשרשרת האספקה. האתגרים המרכזיים כללו צורך במערכת שתדע להגיב לשינויים בשטח בזמן אמת, תוך שמירה על רמות שירות גבוהות ללקוח ועלות נמוכה. לשם כך, נבחנו מספר מודלים קיימים לניהול מלאי כמו (Continuous Review), (EOQ) ו (Newsvendor) אך נמצא כי יש צורך בגישה חכמה ודינמית יותר המשלבת כלים חיזויים ולמידת מכונה, המאפשרת התאמה לתנודות חריגות ושינויים פתאומיים.

המערכת שפותחה בפרויקט שילבה בין מתודולוגיה מסורתית לניהול מלאי לבין יכולות של אלגוריתמים מתקדמים, ובראשם (Random Forest) לצורך שיפור תחזיות הביקוש והתאמתן לרמות השירות בפועל. המערכת בנויה על פלטפורמה פשוטה ונגישה באקסל, ומספקת פתרון שלם הכולל תחזית, חישוב כמויות להזמנה, ותרגום ישיר להמלצות פעולה מול ספקים. בכך, נוצר כלי המאפשר חיזוי מושכל, יעיל תהליך ההזמנה וקבלת החלטות מבוססת נתונים גם בסביבת שטח שאינה דיגיטלית במלואה.

הפרויקט כלל שלב יישום משמעותי שנערך בסניף "קשת טעמים", במחלקת חומרי הניקוי. במהלך תקופה של כחודשיים וחצי, נאספו נתוני ביקוש בפועל, בוצעו תחזיות על בסיס המודל, והוזמנו מוצרים בפועל מול סוכנים בהתאם לתחזיות. הממצאים שהתקבלו מהשטח הדגימו ירידה חדה בימי מלאי אפס, צמצום בכמות ההזמנות, ושיפור ברמת ההתאמה בין התחזית לצריכה האמיתית בפועל. יישום זה אפשר לבחון את המערכת לא רק כתיאוריה מתקדמת, אלא ככלי פרקטי ויעיל שפועל בסביבת שוק אמיתית ומורכבת.

לצד היישום הממשי, נערכו ניתוחים סטטיסטיים מקיפים שהשוו בין ביצועי המודל החכם לבין מודלים מסורתיים. המודל החדש הציג ביצועים עדיפים בכל מדדי התחזית (MAE , $RMSE$, R^2), והוכיח את יכולתו לזהות דפוסים חריגים ולשפר את הדיוק החזוי לאורך זמן. השילוב בין אלגוריתם Random Forest הניתוחים הכמותיים וממשק אקסל פשוט, הפך את המערכת למתאימה במיוחד לסביבות קמעונאיות מבוזרות, שאינן מסתמכות על מערכות ERP מורכבות.

הדו"ח שלפניכם מציג את כל שלבי הפיתוח, הבדיקה, היישום וההערכה של המערכת המוצעת. מטרתו להציג את התרומה של המודל החכם לניהול מלאי בשטח, את היתרונות לעומת הגישות הקיימות, ואת היכולת להרחיב את השימוש במודל לחנויות נוספות. המסקנה המרכזית שעולה היא כי השילוב בין כלים מתקדמים ויישום פשוט הוא המפתח לשיפור תפעולי אמיתי.

מטרות הפרויקט

מטרות ממוקדות

(1) מקסום זמינות המוצרים:

הפחתה משמעותית של ימי חוסר במלאי באמצעות דיוק בנקודות ההזמנה מחדש (ROP), מה שמאפשר לצמצם פגיעה בשביעות רצון הלקוחות ולמנוע אובדן הכנסות, שמירה על רמות מלאי מספיקות להבטחת זמינות גבוהה ללקוחות תוך מניעת מצבי חוסר הפוגעים בתדמית הארגון.

(2) צמצום עלויות מלאי וחוסרים:

איזון בין עלויות אחזקת המלאי, עלויות ההזמנה ועלויות החוסרים באמצעות שימוש באופטימיזציה של הכמויות המוזמנות (EOQ), על מנת למזער את ההוצאות הכוללות של הארגון, שימוש במודל חיזוי מבוסס Random Forest להפחתת עלויות עקב דיוק גבוה יותר בתחזיות ביקוש וזמני אספקה, המוביל לתכנון מלאי מדויק יותר ומניעת בזבז משאבים מיותרים.

(3) ייעול תהליך קבלת ההחלטות:

שילוב מודל למידת מכונה Random Forest המספק תחזיות מדויקות יותר ומפשט את תהליך קבלת ההחלטות הניהוליות, על ידי צמצום טעויות והורדת אי הוודאות בתהליך, פיתוח ממשק מבוסס Excel המאפשר ניטור, מדידה והערכה של ביצועי המלאי בזמן אמת, המספק למנהלים כלים ברורים ונגישים לקבלת החלטות יעילה ומושכלת.

(4) שיפור רציפות האספקה:

קביעת מדיניות הזמנה אופטימלית המבוססת על סימולציות סטטיסטיות רחבות-היקף, המאפשרות הבנה עמוקה של ההשפעה של שינוי בפרמטרים שונים על ביצועי המלאי, מזעור תנודות וזמני השבתה באמצעות מודלים המשלבים נתוני עבר בזמן אמת עם תחזיות ממודלים סטטיסטיים ולמידת מכונה, ובכך הבטחת זרימה רציפה ויציבה של סחורה.

(5) שדרוג מערכת הניהול המבוססת Excel:

אוטומציה של תהליכי ניתוח והפקת דוחות ביצועים תקופתיים, המאפשרת לצוותים התפעוליים להתמקד בפעולות אסטרטגיות ושיפור ביצועי המלאי, התאמת המערכת לקליטת נתונים ועדכונים אוטומטיים לצורך תגובה מהירה ויעילה לתנאים משתנים בשוק, ובכך מאפשרת לארגון להיות גמיש וזריז יותר בקבלת ההחלטות ובהתמודדות עם שינויים פתאומיים.

(6) שיפור דיוק התחזית:

שיפור יכולת החיזוי של ביקושים עתידיים באמצעות שילוב אלגוריתמים מתקדמים ללמידת מכונה, בדגש על (Random Forest) במטרה להקטין את הפער בין הביקוש החזוי לביקוש בפועל. באמצעות מתודולוגיות חיזוי מבוססות נתונים, ניתן לדייק את התחזיות ולהתאימן לתנודתיות בשוק, לעונתיות, ולדפוסי רכישה משתנים. דיוק תחזיות גבוה יותר מאפשר תכנון מלאי מדויק, צמצום חוסרים והפחתת עלויות – ובכך תורם לביצועים תפעוליים ואסטרטגיים טובים יותר של הארגון.

מדדים ויעדים

הפרויקט מתמקד בפיתוח מערכת מתקדמת לניהול מלאי במטרה למקסם את זמינות המוצרים, להפחית עלויות ולייעל את קבלת ההחלטות. להלן מדדי ההצלחה הכמותיים העיקריים שנבחרו לשמש בסיס להערכת הביצועים של המערכת:

(1) רמת זמינות מלאי:

✓ **יעד:** השגת זמינות מוצרים בשיעור של לפחות 95%.

✓ **מדידה:** אחוז הימים מתוך כלל תקופת המדידה שבהם לא היה חוסר במלאי.

(2) מספר אירועי חוסר מלאי:

✓ **יעד:** הפחתת מספר אירועי החוסר במלאי ב-50% לפחות ביחס למצב הנוכחי.

✓ **מדידה:** מניית מספר הפעמים שבהן היה חוסר מלאי בכל תקופה נתונה (חודש/רבעון).

(3) עלות כוללת לניהול מלאי:

✓ **יעד:** צמצום העלות הכוללת לניהול מלאי (הכוללת עלות הזמנות, אחזקת מלאי ועלויות חוסר) ב-5% לפחות.

✓ **מדידה:** סיכום כלל העלויות הכרוכות בניהול המלאי והשוואה מול עלויות במצב הקיים.

(4) תדירות הזמנות:

✓ **יעד:** קביעת מספר אופטימלי של הזמנות להפחתת עלויות התפעול והלוגיסטיקה.

✓ **מדידה:** ספירת מספר ההזמנות הכולל בכל תקופה, תוך כוונה לשמור על איזון בין עלות הזמנות לעלות אחזקת מלאי.

(5) הפחתת זמן חוסר מלאי:

✓ **יעד:** הקטנת משך הזמן הכולל (בימים) שבו המלאי אפס ב-40% לפחות.

✓ **מדידה:** סיכום ימי החוסר לאורך תקופת המדידה.

(6) דיוק התחזית (R^2):

✓ **יעד:** שיפור מקדם ההסבר R^2 של המודל לרמה של מעל 0.9, כך שהתחזית תסביר בצורה גבוהה את הביקוש בפועל.

✓ **מדידה:** חישוב ערך R^2 עבור תחזיות המודל בהשוואה לנתוני הביקוש בפועל לאורך תקופת המדידה.

סקר ספרות

מבוא לסקר הספרות

סקר הספרות בפרויקט זה נועד לסקור את התיאוריות, המודלים והשיטות המרכזיות בתחום ניהול המלאי, תוך דגש מיוחד על שיטות מתקדמות הכוללות מודלים מתמטיים וטכנולוגיות למידת מכונה. מטרת סקר הספרות היא להציג באופן ברור ומקיף את הבסיס המדעי והתיאורטי עליו נשען הפרויקט, ולהבין את היתרונות והחסרונות של השיטות הקיימות בתחום זה.

הסקר יתחיל בהצגת מודל Economic Order Quantity (EOQ) שהוא אחד המודלים הקלאסיים והנפוצים ביותר בניהול מלאי. יוסברו ההנחות העומדות בבסיס המודל, המשוואות המרכזיות, והמצבים בהם השימוש במודל מתאים במיוחד. לאחר מכן, יוצג מודל Continuous Review (Q,R) המתאים יותר לסביבות בהן קיימת אי-ודאות גבוהה בביקוש ובזמני האספקה.

בהמשך הסקר ייבחנו שיטות למידת מכונה, עם דגש מיוחד על אלגוריתם Random Forest הידוע ביכולתו להתמודד עם נתונים מורכבים וקשרים לא ליניאריים. סקר הספרות יתאר כיצד שיטות אלו מסייעות לשפר את דיוק התחזיות בניהול מלאי, ומדוע הן הפכו לפתרון מועדף במקרים רבים בהשוואה לשיטות מסורתיות יותר.

לסיכום, סקר הספרות יספק את התשתית התיאורטית הנדרשת להבנת ההחלטות שהתקבלו במסגרת הפרויקט, וכן יסייע בהצדקת הבחירה במודלים ובטכנולוגיות שנבחרו לפיתוח המודל החדש לניהול מלאי מתקדם.

מודל Economic Order Quantity (EOQ)

מודל- (EOQ) פותח לראשונה על ידי פורד האריס בשנת 1913, ומטרתו העיקרית היא לקבוע את הכמות האופטימלית שיש להזמין במטרה למזער את סך העלויות של הזמנות ואחזקת המלאי. המודל מניח שביקוש המוצרים הוא יציב וקבוע, וזמני האספקה ידועים מראש ללא כל סטיות או שינויים משמעותיים. בכך, המודל מתאים במיוחד לתעשיות שבהן המוצרים והצרכים הם בעלי ביקוש קבוע לאורך זמן¹.

ההנחות הבסיסיות של מודל EOQ כוללות ביקוש שנתי קבוע וידוע מראש, זמני אספקה יציבים ללא אי ודאות, עלויות קבועות ומוגדרות מראש לכל הזמנה, וכן עלות אחזקת מלאי שנתית קבועה לכל יחידה המאוחסנת במחסן. בשל פשטות ההנחות, מודל זה זוכה לשימוש נרחב במערכות ניהול מלאי של חברות שונות בתעשייה ובמסחר.

המשוואה המרכזית של מודל EOQ מחושבת לפי השורש הריבועי של היחס בין הכפלת כמות הביקוש השנתי (D) בעלות ההזמנה הקבועה (S), לבין עלות האחזקה השנתית של יחידה אחת (H) המשוואה היא:

$$EOQ = \sqrt{\frac{2DS}{H}}$$

כאשר הביקוש הוא שנתי, העלות הקבועה להזמנה ידועה מראש, ועלות האחזקה נקבעת לפי תנאי האחסון ועלויות התפעול של החברה².

המודל EOQ הוא מודל דטרמיניסטי שאינו מתחשב באי ודאות או שינויים אקראיים בביקוש או בזמן האספקה. לפיכך, השימוש במודל זה מתאים במיוחד למערכות יציבות בהן השונות והאי ודאות מזעריות, כגון תהליכי ייצור המוניים או מוצרים בעלי ביקוש ידוע ויציב לאורך זמן.

נקודת ההזמנה מחדש (ROP) במודל EOQ מחושבת על ידי הכפלת הביקוש היומי הממוצע בזמן האספקה. כלומר, $ROP = d \times L$, כאשר d מייצג את הביקוש היומי הממוצע, L את זמן האספקה. הנוסחה הפשוטה הזו מאפשרת לעסקים להימנע ממצבי חוסר במלאי על ידי הזמנה בזמן הנכון.

הפשטות של מודל EOQ והקלות בשימוש בו הופכות אותו לפופולרי מאוד בקרב עסקים ותעשיות שונים, במיוחד בתחומים שבהם קיימת יכולת חיזוי טובה והביקוש הוא יציב. דוגמאות לכך הן בתעשיות ייצור סדרתי או בעסקים עם ביקוש קבוע, בהם קל יותר להעריך באופן מדויק את הכמויות והעלויות³.

למרות הפופולריות, אחת הביקורות העיקריות על מודל EOQ היא ההתעלמות מאי-ודאות, עובדה שמגבילה את היישום שלו במציאות משתנה. לכן מומלץ לשלב את המודל עם שיטות מתקדמות יותר, כגון מודלי Q,R או Newsvendor, וכן עם טכניקות ניבוי ביקוש מתקדמות כגון למידת מכונה, כדי לשפר את הדיוק והאפקטיביות של המערכת הכוללת לניהול מלאי.

¹ Harris, 1913, p. 48

² Silver, Pyke & Thomas, 2016, p. 231

³ Nahmias & Olsen, 2015, p. 213

מודל (Q,R) Continuous Review

מודל Continuous Review הידוע גם כמודל (Q,R) הוא שיטה נפוצה בניהול מלאי שנועדה להתמודד עם אי ודאות בביקוש ובזמני האספקה. המודל מנטר את רמות המלאי באופן רציף, ובכך מאפשר הזמנה מחודשת ברגע שהמלאי מגיע לנקודה שנקבעה מראש (Reorder Point - R). המודל מבטיח אספקה שוטפת ומניעת חוסרים.

המודל מבוסס על שני פרמטרים עיקריים: כמות ההזמנה האופטימלית (Q) ונקודת ההזמנה מחדש (R). כמות ההזמנה (Q) מחושבת בדרך כלל באמצעות מודל EOQ הבסיסי, ואילו נקודת ההזמנה מחדש (R) מבוססת על הביקוש הממוצע וזמן האספקה הממוצע, בשילוב של מלאי ביטחון הנועד לכסות שינויים בביקוש וזמני אספקה משתנים⁴.

המשוואה לחישוב נקודת ההזמנה מחדש (R) במודל זה היא:

$$ROP = d * L + z * \sigma_{dL}$$

כאשר d הוא הביקוש היומי הממוצע, L הוא זמן האספקה הממוצע, z הוא מקדם הביטחון (לפי רמת השירות הנדרשת), ו σ_{dL} היא סטיית התקן של הביקוש לאורך זמן האספקה.

מלאי הביטחון מהווה גורם מרכזי במודל Continuous Review מכיוון שהוא מאפשר להתמודד עם אי ודאות. גובה מלאי הביטחון נקבע לפי רמת השירות הרצויה, המחושבת בדרך כלל לפי התפלגות נורמלית של הביקוש וזמן האספקה. ככל שהארגון מעוניין ברמת שירות גבוהה יותר, מלאי הביטחון שיידרש יהיה גבוה יותר⁵.

היתרון המרכזי של מודל (Q,R) הוא יכולתו להבטיח זמינות גבוהה של מוצרים ולהקטין משמעותית את הסיכוי לחוסרים. עם זאת, החיסרון העיקרי של מודל זה הוא עלויות האחזקה הגבוהות יחסית שנובעות מהחזקת מלאי ביטחון משמעותי.

מודל Continuous Review מתאים במיוחד למוצרים בעלי ביקוש משתנה ואקראי, כמו גם במצבים שבהם זמן האספקה אינו ידוע במדויק. מודל זה נפוץ בתחומי קמעונאות ומוצרים תעשייתיים בהם החוסר יכול לגרום לאובדן לקוחות או נזק תפעולי משמעותי⁶.

במודל זה, רמת השירות הרצויה (Service Level) מוגדרת באופן כמותי באמצעות ההסתברות לאי-חוסר מלאי במחזור הזמנה יחיד. מדידה זו מאפשרת לארגונים להגדיר במדויק עד כמה הם מוכנים להשקיע במלאי ביטחון בכדי למנוע חוסרים.

ארגונים המשתמשים במודל (Q,R) מבצעים לרוב ניתוחי רגישות כדי להעריך את ההשפעה של שינויים בפרמטרים כגון הביקוש, זמן האספקה ורמת השירות. ניתוח רגישות מסייע באופטימיזציה של המודל ובהתאמתו למציאות המשתנה של השוק⁷.

⁴ Nahmias & Olsen, 2015, p. 245

⁵ Chopra & Meindl, 2019, p. 312

⁶ Shapiro, 2007, p. 138

⁷ Chopra & Meindl, 2019, p. 320

למידת מכונה וסוגיה

למידת מכונה (Machine Learning - ML) היא תחום במדעי המחשב המאפשר למערכות ללמוד מתוך נתונים, לזהות דפוסים, ולבצע תחזיות ללא תכנות מפורש מראש. שיטות למידת מכונה מאפשרות להתמודד עם נתונים מורכבים ולהתאים עצמן לשינויים בנתונים, מה שהופך אותן למתאימות במיוחד לניהול מלאי ולתחזיות ביקוש.

ניתן לסווג את למידת המכונה לשלושה סוגים עיקריים: למידה מפקחת (Supervised Learning), למידה לא מפקחת (Unsupervised Learning), ולמידת חיזוק (Reinforcement Learning), כל אחת מהשיטות מתאימה לסוגים שונים של בעיות עסקיות ונתונים.⁸

בלמידה מפקחת המודל לומד מנתונים מתויגים, כאשר לכל דוגמה מוגדרת תוצאה ידועה מראש. שיטה זו מתאימה במיוחד לניבוי ביקושים, סיווג מוצרים והחלטות אחרות בניהול מלאי. דוגמאות נפוצות הן רגרסיה לינארית ורשתות עצביות.

מודל הרגרסיה הלינארית (Linear Regression) הוא מודל פשוט ויעיל לניבוי משתנה רציף על בסיס משתנים בלתי תלויים. משוואת המודל מוגדרת באופן הבא $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$ כאשר Y הוא המשתנה התלוי X , הם המשתנים הבלתי תלויים, β הם המקדמים שהמודל מעריך.⁹

שיטת למידה לא מפקחת (Unsupervised Learning) מיועדת לניתוח מבני של נתונים ללא תיוג או ללא תוצאה מוגדרת מראש. שיטות אלה כוללות אלגוריתמי קיבוץ כגון K-means המשמשים לקיבוץ מוצרים או לקוחות לפי דפוסים של ביקוש והתנהגות.

שימוש בשיטות למידת מכונה מאפשר להתמודד ביעילות עם אי ודאות, קשרים מורכבים בין משתנים, ונתונים רבים ובלתי סדורים. שיטות כגון עצי החלטה (Decision Trees) ויער אקראי (Random Forest) מצטיינות בזיהוי קשרים לא לינאריים ועמידות בפני נתונים חריגים.

מחקרים רבים הדגישו את היתרונות של שימוש במודלים מתקדמים כגון רשתות עצביות עמוקות Deep Neural Networks לניבוי ביקוש. מודלים אלו מתמודדים היטב עם נתונים מורכבים, מזהים תבניות עמוקות, ומציגים תוצאות טובות במיוחד בנתוני ביקוש לא לינאריים ומשתנים.¹⁰

לסיכום, שילוב למידת מכונה במערכות ניהול מלאי מספק כלי רב עוצמה לניבוי מדויק והתמודדות עם מצבים מורכבים ואי ודאות בשוק. יישום מוצלח של מודלים אלה מחייב הבנה עמוקה של סוגי הנתונים, מודלים שונים, והתאמתם המדויקת לצרכי הארגון.¹¹

⁸ Russell & Norvig, 2020, p. 698

⁹ James et al., 2013, p. 61

¹⁰ Goodfellow, Bengio & Courville, 2016, p. 165

¹¹ Russell & Norvig, 2020, p. 720

רגרסיה לינארית

רגרסיה לינארית היא אחת השיטות הבסיסיות והנפוצות ביותר בניתוח סטטיסטי ובחיזוי. המודל מאפשר לתאר את הקשר הלינארי בין משתנה תלוי אחד או יותר למשתנה בלתי תלוי, ומיושם באופן רחב בתחומים רבים כולל כלכלה, ניהול, ומדעי הנתונים.

הנחת הבסיס של רגרסיה לינארית היא כי הקשר בין המשתנים הוא לינארי, ולכן ניתן לבטא את הקשר בעזרת קו ישר. המשוואה היסודית של רגרסיה לינארית פשוטה מוגדרת כך:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$$

כאשר Y הוא המשתנה התלוי X , המשתנה הבלתי תלוי β_0 , הוא החותך β_1 , הוא מקדם השיפוע, ו ϵ הוא טעות אקראית.¹²

המודל הלינארי מניח מספר הנחות סטטיסטיות הכוללות נורמליות של טעויות, הומוסקדסטיות (שוויון שונויות), אי-תלות בין טעויות, והיעדר רב-קולינאריות חמורה בין המשתנים הבלתי תלויים.

אימות מודל הרגרסיה מתבצע באמצעות מדדים סטטיסטיים שונים כגון R^2 המספק מידע על שיעור השונות במשתנה התלוי המוסבר על ידי המודל. ערך גבוה של R^2 מעיד על איכות טובה יותר של המודל בהתאמת הנתונים.¹³

השימוש ברגרסיה לינארית הוא נפוץ במיוחד בתחומי הניהול והכלכלה, לניבוי ביקוש, חיזוי מכירות, וניתוח מגמות בשווקים. מודל זה מספק פתרונות ברורים וקליטים לניהול מלאי ולהחלטות תפעוליות.

עם זאת, הרגרסיה הלינארית רגישה מאוד לנתונים חריגים (Outliers) ולכן יש לבצע אבחון זהיר של הנתונים ולהשתמש בשיטות חזקות יותר או בטכניקות לניהול ערכים חריגים כאשר הם קיימים בנתונים.¹⁴

ערכים חריגים (Outliers) הם תצפיות שנמצאות במרחק רב משאר הנתונים ונגרמות מטעויות מדידה, טעויות הקלדה או אירועים נדירים. זיהוי חריגים נעשה באמצעות סטיית תקן, תיבות וסרגלים, גרפים מפוזרים (Boxplot) ומדדים סטטיסטיים. הטיפול בהם כולל הסרה, טרנספורמציה, שימוש במודלים רובסטיים, אמפוטציה, נורמליזציה וזיהוי ממוקד באמצעות אלגוריתמים. חשוב לבחון בזהירות את הנתונים כדי להימנע מהשפעה שלילית על מודלים כמו רגרסיה לינארית, הרגישה לערכים חריגים.

לרגרסיה לינארית קיימות גם מגבלות משמעותיות כאשר הקשרים בין המשתנים אינם לינאריים. במקרים כאלו, השימוש במודלים אחרים כגון רגרסיה פולינומאלית, עצי החלטה או רשתות עצביות עשוי לספק תוצאות מדויקות יותר.

כדי להבטיח את הדיוק והיעילות של מודל הרגרסיה הלינארית לאורך זמן, יש לבצע ניטור רציף של ביצועי המודל, התאמות ועדכונים של המודל בהתאם לנתונים חדשים, ולשלב ניתוח רגישות להערכת ההשפעה של שינויים בנתונים ובפרמטרים על התוצאות.¹⁵

¹² Montgomery et al., 2012, p. 14

¹³ Montgomery et al., 2012, p. 42

¹⁴ Kutner et al., 2005, p. 98

¹⁵ James et al., 2013, p. 75

סקר ספרותי Random Forest

Random Forest (יער אקראי) היא שיטת למידת מכונה מתקדמת המבוססת על שילוב מספר גדול של עצי החלטה, שמטרתה לשפר את דיוק הניבוי ולמנוע בעיות של התאמת יתר (Overfitting). השיטה הוצגה לראשונה על ידי בריימן בשנת 2001 והיא נפוצה מאוד בתחומים רבים כמו ניהול מלאי, חיזוי ביקושים, וסיווג נתונים.

האלגוריתם של Random Forest בונה מספר רב של עצי החלטה, שכל אחד מהם מאומן על קבוצת נתונים שונה, המתקבלת מדגימה אקראית (Bootstrap sample). כל עץ החלטה מנבא באופן עצמאי, והתחזית הסופית מתקבלת באמצעות ממוצע תוצאות העצים לרגרסיה או לפי הצבעת רוב עבור סיווג.¹⁶

יתרון משמעותי של Random Forest הוא יכולתו להתמודד ביעילות רבה עם נתונים לא ליניאריים ומורכבים. בשל השימוש בעצים רבים, השיטה יכולה לגלות קשרים עמוקים וסמויים בין משתנים, תוך התמודדות מצוינת עם נתונים חריגים.¹⁷

אחד המאפיינים המרכזיים של Random Forest הוא השימוש בבחירת משתנים אקראית בעת בניית כל עץ. האלגוריתם בוחר רק חלק קטן מהמשתנים הזמינים בכל שלב של פיצול ענפים, מה שמפחית את הקורלציה בין העצים ומגדיל את הגיוון במודל, וכתוצאה מכך משפר את יכולת ההכללה.

רמת החשיבות של המשתנים (Variable Importance) נמדדת באלגוריתם Random Forest באמצעות הערכת הירידה הממוצעת בטעות החיזוי בכל העצים בהם משתנה מסוים מופיע. משתנים בעלי חשיבות גבוהה משפרים משמעותית את דיוק המודל.

מחקרים מראים כי Random Forest מציע ביצועים יציבים וטובים משמעותית בהשוואה לשיטות אחרות, במיוחד במצבים בהם קיימים נתונים חסרים או רעש רב בנתונים. תכונה זו מאפשרת לשיטה לשמור על דיוק גבוה לאורך זמן ובמצבים מגוונים.¹⁸

הערכת הביצועים של Random Forest מתבצעת בדרך כלל באמצעות מתודולוגיית Out-of-Bag (OOB) בכל דגימת bootstrap חלק מהנתונים לא נבחרים, ונתונים אלו משמשים להערכת השגיאה של המודל, מה שמספק הערכה אמينة של הביצועים ללא צורך בנתונים נוספים לבדיקת המודל.

מודל Random Forest גם מאפשר בקלות כוונן פרמטרים (Hyperparameter tuning) כמו מספר העצים, עומק העצים, וכמות המשתנים לפיצול, כדי להשיג אופטימיזציה גבוהה של התוצאות ולהתאים את המודל לצרכים ספציפיים של בעיה נתונה.

לסיכום Random Forest הוא אלגוריתם חזק, גמיש ומדויק, המתאים למגוון רחב של יישומים בתחום ניהול מלאי וניבוי ביקוש. השימוש בשיטה זו נפוץ בזכות עמידותה בפני טעויות ואיכות הניבוי הגבוהה, במיוחד בסביבות נתונים מורכבות ואי ודאיות.¹⁹

¹⁶ James et al., 2013, p. 316


¹⁷ Hastie, Tibshirani & Friedman, 2009, p. 588

¹⁸ Murphy, 2012, p. 557

¹⁹ Goodfellow, Bengio & Courville, 2016, p. 282

מתודולוגיה (שיטת SDLC)

הפרויקט לניהול מלאי מתקדם יפותח באמצעות מתודולוגיית מחזור החיים (System Development Life Cycle - SDLC), אשר תאפשר ניהול מובנה ומסודר של שלבי הפיתוח תוך מתן מענה מיטבי לדרישות המשתמשים וליעדים העסקיים של הפרויקט:



אובייקט 1 שלבי שיטת SDLC

להלן פירוט נרחב ומורחב של חמשת השלבים העיקריים ביישום המתודולוגיה בפרויקט, כולל פירוט הכלים ותכני הסימולציה:

שלב 1: תכנון (Planning) שלב התכנון הוא השלב הראשון והקריטי ביותר במחזור החיים של פיתוח מערכת מידע. בשלב זה נקבעות המטרות והיעדים הברורים לפרויקט, מוגדרת אסטרטגיית העבודה, ומפותחת תכנית עבודה מפורטת שתבטיח את הצלחתו. שלב זה כולל את הגדרת המשאבים הנדרשים, כולל כוח אדם מיומן, חומרה מתאימה, תוכנות רלוונטיות ותקציב מפורט ומדויק. תבוצע הערכת עלויות ולוחות זמנים מדויקים, כולל קביעת אבני דרך להערכת התקדמות לאורך הדרך. יבוצעו פעילויות לזיהוי סיכונים אפשריים העלולים להשפיע על הפרויקט, וייקבעו תוכניות ניהול סיכונים מתאימות.

שלב 2: ניתוח (Analysis) שלב הניתוח כולל ניתוח מעמיק ומפורט של דרישות המשתמשים, תהליכים עסקיים וצרכים ארגוניים. בשלב זה יתבצעו ראיונות מובנים עם גורמים מרכזיים בארגון, וכן יתקיימו פגישות ותצפיות ישירות על מנת לזהות במדויק את הצרכים של המשתמשים השונים. תבוצע סקירה מקיפה של מערכות קיימות בשוק ושל טכנולוגיות מתקדמות לניהול מלאי, כולל מודלים מתמטיים כגון EOQ, Newsvendor, Continuous Review. בשלב זה תבוצע גם אנליזה של נתונים קיימים באמצעות Excel ו-R לניתוח סטטיסטי ראשוני. תוצאות הניתוח יתועדו במסמך אפיון דרישות (Software Requirements Specification – SRS), המסמך יכלול דרישות פונקציונליות, דרישות לא פונקציונליות, דרישות ביצועים, דרישות אבטחה, ומפרטי ממשקים למערכות קיימות.

שלב 3: עיצוב (Design) בשלב העיצוב תוגדר במדויק ארכיטקטורת המערכת, יפותח עיצוב מפורט של בסיס הנתונים, ויעוצבו הממשקים והמסכים בהתאם לצרכים שהוגדרו. ייעשה שימוש בדיאגרמות UML לתיאור ויזואלי של ארכיטקטורת המערכת, זרימות נתונים, וקשרים בין רכיבים שונים. בשלב יוגדרו האלגוריתמים המתמטיים שישולבו במערכת. (EOQ, Continuous Review, Newsvendor) האלגוריתמים ישמשו

לניהול יעיל של מלאי, קביעת נקודות הזמנה מחדש, מלאי ביטחון, וכמויות אופטימליות להזמנה. בשלב זה יוגדרו גם מדדי ביצועים (KPIs) כמו עלויות אחזקת מלאי, עלויות הזמנה, מספר אירועי חוסר וזמינות מלאי גבוהה.


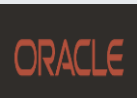



שלב 4: מימוש (Implementation) הפרויקט כלל שלב יישום משמעותי שנערך בסניף "קשת טעמים", במחלקת חומרי הניקוי. במהלך תקופה של כחודשיים וחצי, נאספו נתוני ביקוש בפועל, בוצעו תחזיות על בסיס המודל, והוזמנו מוצרים בפועל מול סוכנים בהתאם לתחזיות. הממצאים שהתקבלו מהשטח הדגימו ירידה חדה בימי מלאי אפס, צמצום בכמות ההזמנות, ושיפור ברמת ההתאמה בין התחזית לצריכה האמיתית בפועל. יישום זה אפשר לבחון את המערכת לא רק כתיאוריה מתקדמת, אלא ככלי פרקטי ויעיל שפועל בסביבת שוק אמיתית ומורכבת.

שלב 5: תחזוקה (Maintenance) שלב התחזוקה כולל את ההטמעה המעשית של המערכת בסביבה ארגונית נבחרת. בשלב זה יתבצעו בדיקות יסודיות Unit Testing ו System Testing-לווידוא תקינות ויציבות המערכת. לאחר ההטמעה, תתקיים הדרכה מסודרת למשתמשים, ותבוצע תחזוקה שוטפת, כולל תיקון תקלות, מתן תמיכה טכנית וביצוע עדכונים בהתאם לשינויים בדרישות או בטכנולוגיות. תיעשה הערכה תקופתית של ביצועי המערכת באמצעות המדדים שהוגדרו (KPIs), תוך שימוש בכלי Excel לבדיקות אוטומטיות והפקת דוחות תקופתיים. המערכת תעבור אופטימיזציה מתמשכת, עם התאמות ועדכונים בהתאם לתוצאות הסימולציות התקופתיות ושינויים בארגון או בשוק.

חקר מצב קיים

חקר מערכות המתחרים

בחקר מצב קיים נעשה חקר מעמיק למערכות המתחרים בשוק:

קישור לאתר הרשמי	שנת השקה	שיטות בשימוש	מערכת ניהול מלאי	
LINK	1998	EOQ, Periodic Review	NetSuite Inventory Management	
LINK	1977	EOQ, Periodic Review	Oracle Inventory Management	
LINK	2015	Periodic Review	Nest Egg	
LINK	2000	Newsvendor Model	Supply Brain	
LINK	1972	EOQ, Periodic Review	SAP Inventory Management	

אובייקט 2 טבלת השוואת עלויות כוללת

מסקנות מחקר המערכות השונות הקיימות בשוק:

1. **שימוש במודלים מסורתיים:** מרבית המערכות שנחקרו מבוססות על מודלים קלאסיים של ניהול מלאי כמו **EOQ (Economic Order Quantity)** ו **Periodic Review** שיטות אלו מתאימות בעיקר למערכות בהן הביקוש יציב יחסית והסביבה אינה משתנה באופן קיצוני. מערכות אלו מציעות פתרונות פשוטים וברורים, אך מוגבלות בהתמודדות עם תנודתיות גבוהה ואי ודאות.


2. **חוסר תמיכה בפתרונות למידת מכונה:** נראה כי אף אחת מהמערכות שנבדקו לא משלבת באופן מובהק שיטות למידת מכונה כמו **Random Forest** או אלגוריתמים מתקדמים אחרים. זהו פער משמעותי שניתן לנצל על ידי פיתוח המערכת שלך, במיוחד כשמדובר במצבים בהם הביקוש משתנה בצורה בלתי צפויה או מורכבת.

3. **פוטנציאל לשיפור באמצעות שילוב למידת מכונה:** מהמחקר עולה כי קיים פער ברור במערכות הקיימות, כאשר אף מערכת לא מנצלת בצורה אופטימלית את יכולות למידת המכונה לחיזוי מדויק יותר של ביקושים וזמני אספקה. שילוב של טכנולוגיות מתקדמות אלה יכול לשפר משמעותית את הדיוק והיעילות של מערכות ניהול המלאי.

לסיכום, המסקנות מראות כי פיתוח המערכת המבוססת על שילוב מודלי למידת מכונה יכול לספק **יתרון תחרותי משמעותי** על פני המערכות המסורתיות הקיימות בשוק.









סימולציה לשיטות קיימות

לצורך השוואה בין שלושת השיטות הקיימות נבנה סימולציה ייחודית לפרויקט בשפת תכנות R, הסימולציה תריץ השיטה עבור המלאי לאורך 800 יום 1000 פעמים, כל פעם עם נתונים שונים



אובייקט 3 סימולציה רמות מלאי

תוצאות הסימולציה נקבל דרך תוכנת R בצורת טבלה של 1000 שורות לכל שיטה

									
	run	zero_inv_events	zero_inv_days	total_cost	total_order_cost	total_holding_cost	total_stockout_cost	num_orders	avg_inv
980	980	9	14	2823.313	1220	903.3126	700	61	412.1364
981	981	14	25	3323.106	1200	873.1059	1250	60	398.3546
982	982	11	20	3126.053	1220	906.0528	1000	61	413.3866
983	983	16	27	3432.005	1200	882.0048	1350	60	402.4147
984	984	19	31	3592.957	1200	842.9569	1550	60	384.5991
985	985	16	35	3841.309	1200	891.3095	1750	60	406.6600
986	986	10	22	3247.424	1220	927.4237	1100	61	423.1371
987	987	16	40	4036.932	1180	856.9318	2000	59	390.9752
988	988	16	26	3375.624	1200	875.6239	1300	60	399.5034
989	989	14	28	3483.401	1200	883.4009	1400	60	403.0516
990	990	15	32	3670.645	1200	870.6453	1600	60	397.2319
991	991	13	25	3371.409	1220	901.4089	1250	61	411.2678
992	992	11	20	3131.452	1220	911.4518	1000	61	415.8499
993	993	12	26	3400.221	1200	900.2211	1300	60	410.7259
994	994	11	20	3127.818	1220	907.8175	1000	61	414.1917
995	995	11	27	3447.582	1200	897.5816	1350	60	409.5216
996	996	15	32	3652.470	1200	852.4700	1600	60	388.9394
997	997	12	20	3110.825	1220	890.8253	1000	61	406.4391
998	998	12	23	3231.385	1200	881.3846	1150	60	402.1317
999	999	15	34	3816.121	1420	696.1210	1700	71	317.6052
1000	1000	17	31	3631.862	1200	881.8616	1550	60	402.3494

אובייקט 4 טבלת תוצאות הסימולציה

מדד ביצוע KPI לסימולציה

הסימולציה מייצרת לנו נתונים מתמקדים במדדי ביצועים עיקריים KPIs הקשורים לניהול מלאי בשלושה מודלים שונים.

מה מודד?	מדד ביצוע KPI	
מספר ההזמנות הכולל שבוצעו במהלך תקופת הבדיקה	<u>num_orders</u> מספר ההזמנות	1
מציין את מספר הפעמים שבהן המלאי הגיע לאפס	<u>zero_inv_events</u> אירועים של מלאי אפס	2
מייצג את מספר הימים שבהם לא היה מלאי זמין.	<u>zero_inv_days</u> ימים עם מלאי אפס	3
סכום העלויות הכולל של ניהול המלאי, המורכב משלושת סוגי העלויות: הזמנה, אחזקה, וחוסר מלאי	<u>total_cost</u> עלות כוללת	4
כולל את כל העלויות הנלוות לתהליך ההזמנה (כגון עלויות טיפול, שינוע וכו').	<u>total_order_cost</u> עלות כוללת של הזמנות	5
העלות הנובעת מאחזקת מלאי במחסן, כגון עלויות אחסון, ביטוח, פחת.	<u>total holding cost</u> עלות כוללת של אחזקת מלאי	6
העלויות שנגרמות כאשר המלאי לא זמין ללקוח, כגון אובדן מכירות, פגיעה באמון הלקוח, ועלויות טיפול בבעיות חריגות.	<u>total stockout cost</u> עלות כוללת של חוסרי מלאי	7

אובייקט 50 מדד ביצוע KPI לסימולציה

❖ כדי להבטיח שהתוצאות שנקבל בסימולציה יהיו אמינות, מדויקות וללא הטיה (Bias), התמקדנו בכמה צעדים מרכזיים:

- נתונים מציאותיים ומבוססים:** דאגנו לכך שהנתונים שאנחנו משתמשים בהם (כגון ביקוש יומי, זמני הובלה) מבוססים על חלוקות הסתברות שמייצגות את המציאות בצורה נכונה.
- הרצת סימולציות מרובות (Replications):** כדי לקבל תוצאות סטטיסטיות מהימנות, הרצנו את הסימולציה מספר רב של פעמים. כך שנוכל לחשב ממוצעים, מדדים ולהקטין את השפעות המקריות.
- ניהול גורם האקראיות (seed):** השתמשנו בזרעי מספרים אקראיים קבועים (seed) בהדמיות, כך שיהיה ניתן לשחזר תוצאות ולהבטיח עקביות בהשוואה בין שיטות שונות.
- ניתוח רגישות:** בדקנו כיצד שינוי בפרמטרים (כמו סטיית התקן, זמן ההובלה, רמת הביטחון) משפיע על התוצאות. כך שנוכל לזהות אילו פרמטרים הם בעלי השפעה משמעותית ולוודא שההנחות שלנו הן סבירות.

❖ כדי לנתח תוצאות הסימולציה בצורה יעילה סיכמנו הנתונים של שלושת השיטות, עבור ממוצע של 1000 ההרצות (Replications) לכל שיטה בנפרד

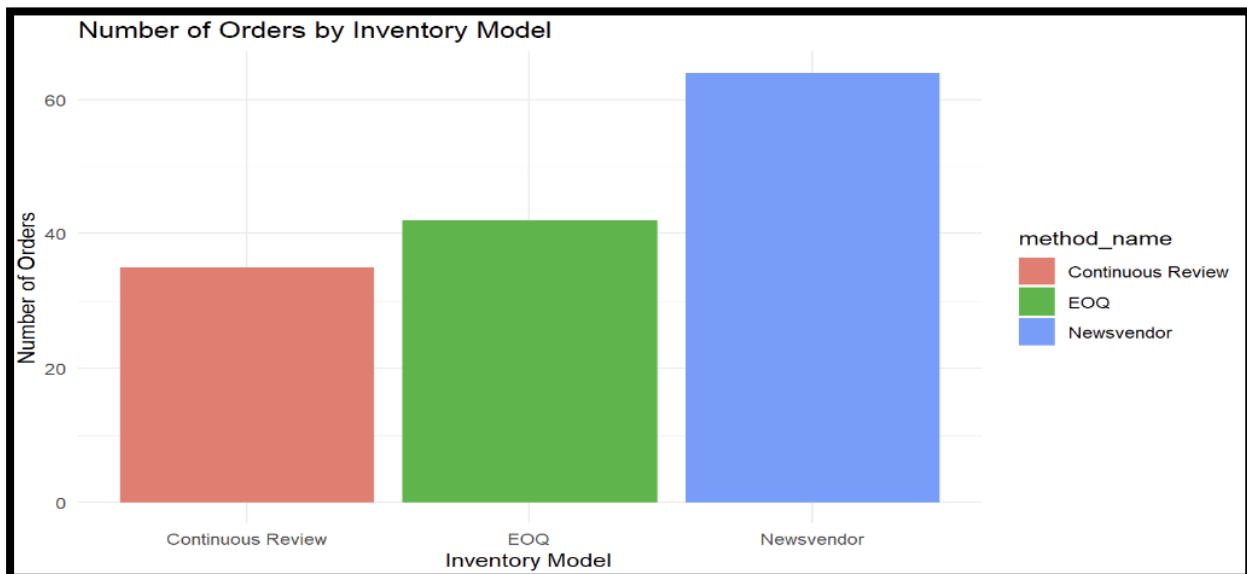
	method_name	num_orders	zero_inv_events	zero_inv_days	total_cost	total_order_cost	total_holding_cost	total_stockout_cost
1	EOQ	42	10.70	21.67	5608	2102	2422	1083
2	Continuous Review	35	7.83	14.63	5436	1773	2930	730
3	News vendor	64	14.00	26.20	6276	3222	1712	1341

אובייקט 6 טבלת נתוני סימולציות

ניתוח תוצאות הסימולציה

❖ מספר ההזמנות שבוצעו בכל מודל

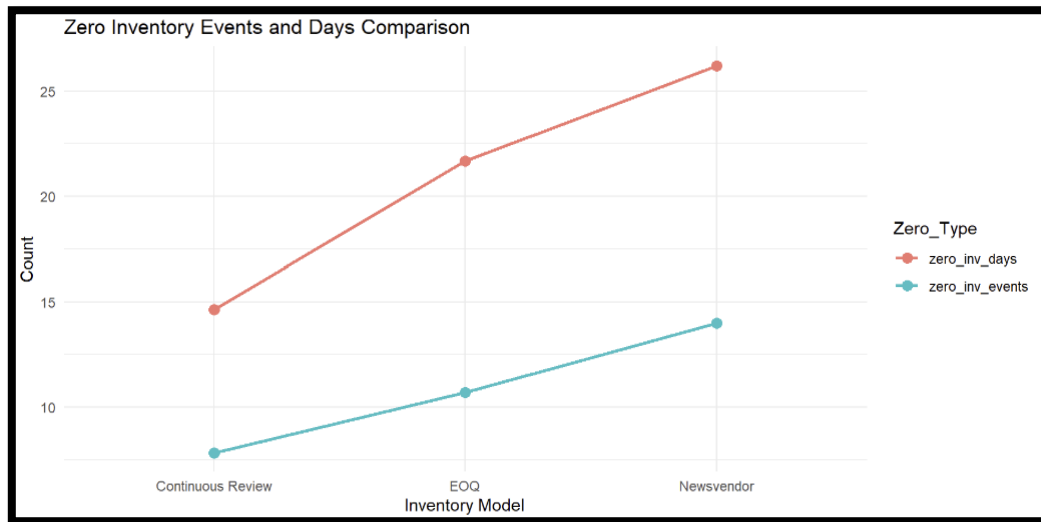
הגרף מציג השוואה בין שלושת מודלי ניהול המלאי לפי מספר ההזמנות, כאשר מיעוט הזמנות מעיד על יעילות גבוהה יותר. ניתן לראות כי מודל Continuous Review הוא היעיל ביותר עם 35 הזמנות בלבד. מודל EOQ נמצא במקום השני עם 42 הזמנות, ואילו מודל ה-News vendor הוא הפחות יעיל מבין השלושה, עם מספר ההזמנות הגבוה ביותר – 64 הזמנות. תוצאות אלו מצביעות על כך שמודל Continuous Review הוא המועדף במונחי יעילות, עקב מספר ההזמנות הנמוך וחסכון בעלויות הכרוכות בהזמנות חוזרות.



אובייקט 7 גרף מספר ההזמנות שבוצעו בכל מודל

❖ מספר האירועים והימים בהם המלאי אזל לחלוטין


הגרף משווה בין שלושת מודלי ניהול המלאי מבחינת מספר האירועים והימים בהם המלאי אזל לחלוטין. ניתן לראות כי מודל Continuous Review מציג את המספר הנמוך ביותר של אירועי אפס מלאי ושל ימי מחסור במלאי, ולכן הוא המודל היעיל ביותר בשמירת רמות מלאי יציבות. לעומתו, מודל ה-News vendor מציג את המספר הגבוה ביותר בשני המדדים, דבר המעיד על סיכון גבוה יותר להישאר ללא מלאי לאורך תקופות ארוכות. מודל EOQ נמצא במקום ביניים בין שני המודלים הללו.



אובייקט 8 גרף מספר האירועים והימים בהם המלאי אזל לחלוטין

❖ עלויות ניהול מלאי בשלושת המודלים

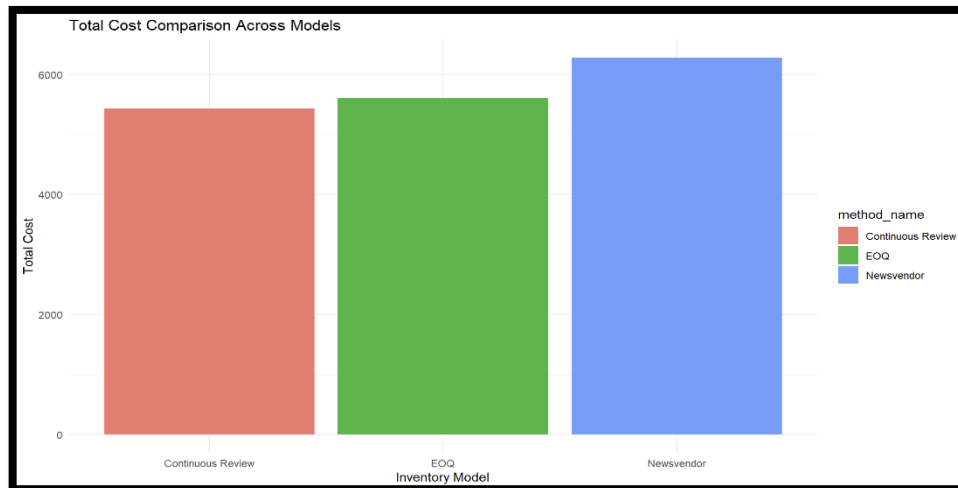
הגרף מציג פילוח של עלויות ניהול מלאי בשלושת המודלים שנבדקו, תוך הבחנה בין עלויות החזקה, הזמנה וחוסר במלאי. ניתן לראות כי מודל Continuous Review מציג את העלות הכוללת הנמוכה ביותר, עם עלויות הזמנה נמוכות במיוחד. מודל EOQ נמצא במקום השני, עם עלויות החזקה גבוהות יותר, בעוד שמודל News vendor הוא היקר ביותר, בעיקר בשל עלויות ההזמנה והחוסר במלאי הגבוהות שלו. לפיכך, מודל Continuous Review מומלץ כמודל חסכוני ויעיל לניהול מלאי.



אובייקט 9 גרף עלויות ניהול מלאי בשלושת המודלים

❖ העלות הכוללת

הגרף משווה את העלות הכוללת של שלושת המודלים לניהול מלאי שנבדקו. מודל Continuous Review מציג את העלות הכוללת הנמוכה ביותר (כ-5,436), ובכך מתבלט כיעיל ביותר מבחינת חיסכון כספי. מודל EOQ מעט יקר יותר (כ-5,608), בעוד מודל Newsvendor הוא היקר ביותר מבין השלושה עם עלות כוללת של כ-6,276. מסקנת ההשוואה היא שהמודל Continuous Review עדיף מבחינה כלכלית לניהול המלאי בארגון.



אובייקט 10 גרף העלות הכוללת

תוצאות

בניית המודל החדש - גרסה ראשונית (Pilot Phase)

אחרי המסקנות שקיבלנו מהסימולציה, החלטנו לבנות מודל ניהול מלאי חדש שמורכב משלושת המודלים הבאים:

(1) מודל למידת מכונה ML (Random forest)

(2) מודל Economic Order Quantity (EOQ)

$$EOQ = \sqrt{\frac{2 \cdot D \cdot S}{H}} \longrightarrow Q^* = \sqrt{\frac{2 \cdot (ML \text{ Demand Prediction}) \cdot S}{H}}$$

(3) מודל Continuous Review (Q,R)

$$ROP = d \cdot L + z \cdot \sigma_{dL}$$

$$ROP = (ML \text{ Avg Daily Demand Prediction}) \cdot (ML \text{ Avg Lead Time Prediction}) + z \cdot (ML \text{ Prediction of } \sigma_{dL})$$

המשוואות המוצגות מבטאות מודל משולב חדש לניהול מלאי, שבו משולבים מודלי למידת מכונה (Random Forest) במקום הממוצעים הפשוטים המקובלים במודלים קלאסיים. במשוואת EOQ, תחזית הביקוש השנתית (D) הוחלפה בתחזית ביקוש שנתית שמתקבלת על ידי מודל למידת המכונה, כדי לשפר את דיוק ההזמנות ולהפחית את העלויות.

במשוואת נקודת ההזמנה מחדש, (ROP) הממוצעים של הביקוש היומי וזמן ההובלה הוחלפו בתחזיות ממודל למידת המכונה, וכך גם סטיית התקן המשולבת של ביקוש וזמן אספקה. שינוי זה מאפשר דיוק רב יותר בזיהוי הזמן המתאים להזמנה מחודשת ומקטין את הסיכון למחסור או עודף במלאי.

❖ **למה בחרנו במודל למידת המכונה Random Forest ולא בחרנו במודל אחר כמו Linear Regression למשל?**

(1) **יחסים לא ליניאריים Nonlinear Relationships :**

- נתוני מלאי (ביקוש וזמן אספקה) מציגים בדרך כלל קשרים לא ליניאריים ומורכבים.

(2) **עמידות גבוהה לנתונים חריגים :**

- המודל מתמודד טוב יותר עם שינויים קיצוניים או חריגים בביקוש או בזמן האספקה.

(3) **רמת דיוק גבוהה :**

- במציאות של ניהול מלאי, Random Forest בדרך כלל מספק תחזיות מדויקות יותר מאשר מודלים ליניאריים פשוטים.

תוצאות ראשוניות למודל החדש

כדי לנתח תוצאות הסימולציה עם המודל החדש בצורה יעילה סיכמנו הנתונים של המודל החדש, עבור ממוצע של 1000 ההרצות (Replications) בהשוואה לכל שיטה בנפרד


	method_name	num_orders	zero_inv_events	zero_inv_days	total_cost	total_order_cost	total_holding_cost	total_stockout_cost
1	EOQ	42.0	10.70	21.67	5608	2102	2422	1083
2	Continuous Review	35.0	7.83	14.63	5436	1773	2930	730
3	Newsvendor	64.0	14.00	26.20	6276	3222	1712	1341
4	New Model	30.1	2.40	7.50	6594	1400	4232	377

אובייקט 11 טבלת נתוני סימולציות מודלים כולל המודל החדש

ניתוח תוצאות הסימולציה עם המודל החדש

❖ מספר ההזמנות של ארבעה מודלים

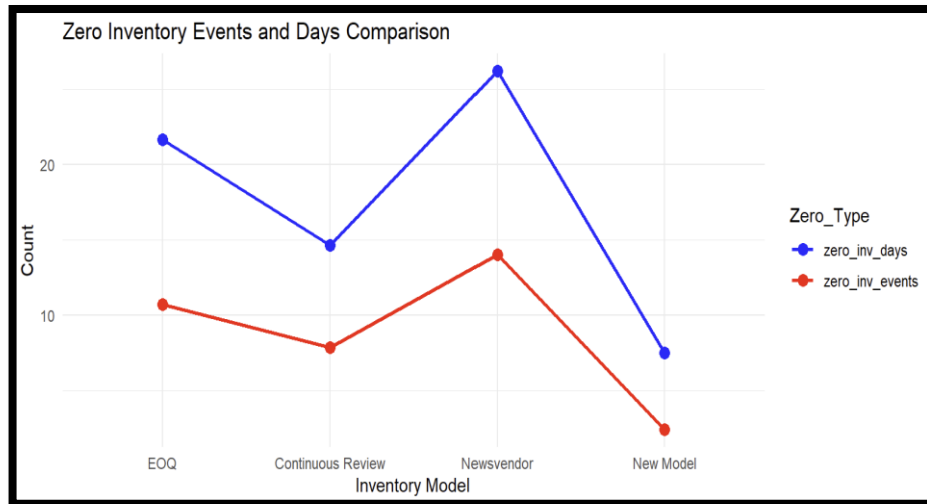
הגרף מציג השוואה בין מספר ההזמנות של ארבעה מודלים לניהול מלאי. המודל החדש (New Model) המשלב למידת מכונה, מציג את הביצועים הטובים ביותר עם המספר הנמוך ביותר של הזמנות (כ-30). מודל ה Newsvendor הוא הפחות יעיל, עם המספר הגבוה ביותר של הזמנות (כ-64), בעוד המודלים EOQ ו-Continuous Review נמצאים באמצע. מכאן עולה שהמודל החדש עדיף משמעותית, משום שהוא מצמצם את כמות ההזמנות ותורם ליעילות תפעולית.



אובייקט 12 גרף מספר ההזמנות של ארבעה מודלים

❖ מספר אירועי וימי אפס מלאי

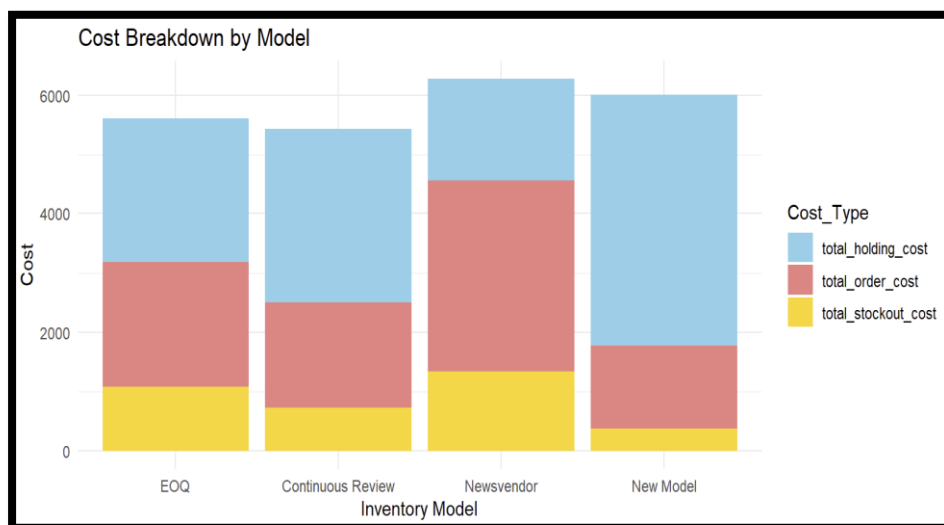
הגרף מציג השוואה בין ארבעת מודלי ניהול המלאי לפי מספר אירועי וימי אפס מלאי. ניתן לראות בבירור שהמודל החדש (New Model), המשלב למידת מכונה, הוא היעיל ביותר, עם המספר הנמוך ביותר הן של אירועי אפס מלאי והן של ימים שבהם לא היה מלאי כלל. לעומתו, מודל Newsvendor הוא בעל הביצועים הגרועים ביותר בשני המדדים. מודלים EOQ ו Continuous Review-מציגים ביצועים בינוניים. תוצאות אלה מדגישות את היתרון של שימוש במודל החדש בהיבטי אמינות וזמינות מלאי.



אובייקט 13גרף מספר אירועי וימי אפס מלאי

❖ הרכב העלויות של ארבעת המודלים

הגרף מציג את הרכב העלויות של ארבעה מודלים לניהול מלאי, תוך התייחסות לעלויות החזקה, הזמנה וחוסר במלאי. המודל החדש (New Model) אמנם מתאפיין בעלות החזקה גבוהה משמעותית משאר המודלים, אך מצטיין בעלויות הזמנה וחוסר מלאי נמוכות מאוד. מודל ה-Newsvendor, לעומת זאת, מראה עלויות גבוהות במיוחד של הזמנה וחוסר מלאי. מודלי EOQ ו Continuous Review-נמצאים בטווח הביניים. לפיכך, המודל החדש אידיאלי לעסקים שבהם חשוב להימנע מחוסר במלאי, גם אם המשמעות היא עלות החזקה גבוהה יותר.



אובייקט 14גרף הרכב העלויות של ארבעת המודלים

בניית המודל החדש - גרסה 2

מעבר בין גרסה 1 ל- גרסה 2 של המודל

גרסה 1 : התבססה רק על משתנים בסיסיים כמו : id, date ,demand ,ללא קשרים קטגוריים.

בגרסה 2 : נוספו משתנים חדשים המסבירים את תנודת הביקוש :

- day, month, year : פרוק לתקופות
- weekday : יום בשבוע
- is_weekend : האם מדובר ביום שישי/שבת
- ✓ תוספת זו שיפרה את יכולת הלמידה של המודל ועזרה לו להבין :
- מתי יש עלייה בביקוש (כמו בסופ"ש)
- מתי יש ירידה עונתית
- אילו ימים מתאפיינים בדפוס חריג

	id	date	demand	day	month	year	weekday	is_weekend
1	4084500088917	2025-01-01	5	1	1	2025	3	0
50	4084500088917	2025-01-02	8	2	1	2025	4	0
99	4084500088917	2025-01-03	8	3	1	2025	5	1
148	4084500088917	2025-01-04	10	4	1	2025	6	1
197	4084500088917	2025-01-05	5	5	1	2025	7	0
246	4084500088917	2025-01-06	5	6	1	2025	1	0
295	4084500088917	2025-01-07	5	7	1	2025	2	0
344	4084500088917	2025-01-08	5	8	1	2025	3	0
393	4084500088917	2025-01-09	4	9	1	2025	4	0
442	4084500088917	2025-01-10	10	10	1	2025	5	1
491	4084500088917	2025-01-11	10	11	1	2025	6	1
540	4084500088917	2025-01-12	5	12	1	2025	7	0
589	4084500088917	2025-01-13	4	13	1	2025	1	0
638	4084500088917	2025-01-14	6	14	1	2025	2	0
687	4084500088917	2025-01-15	4	15	1	2025	3	0
736	4084500088917	2025-01-16	5	16	1	2025	4	0
785	4084500088917	2025-01-17	10	17	1	2025	5	1
834	4084500088917	2025-01-18	8	18	1	2025	6	1
883	4084500088917	2025-01-19	4	19	1	2025	7	0
932	4084500088917	2025-01-20	5	20	1	2025	1	0
981	4084500088917	2025-01-21	5	21	1	2025	2	0
1030	4084500088917	2025-01-22	5	22	1	2025	3	0
1079	4084500088917	2025-01-23	5	23	1	2025	4	0
1128	4084500088917	2025-01-24	10	24	1	2025	5	1
1177	4084500088917	2025-01-25	8	25	1	2025	6	1

אובייקט 15טבלת נתוני ביקוש יומי

תוצאות מעבר בין גרסה 1 ל- גרסה 2 של המודל
מודל חדש (גרסה 1)

```
> cat("Model Evaluation Metrics:\n")
Model Evaluation Metrics:
> cat(paste("MAE (Mean Absolute Error):", round(mae_val, 2), "\n"))
MAE (Mean Absolute Error): 1.26
> cat(paste("RMSE (Root Mean Squared Error):", round(rmse_val, 2), "\n"))
RMSE (Root Mean Squared Error): 1.8
> cat(paste("R² (Coefficient of Determination):", round(r2_val, 4), "\n"))
R² (Coefficient of Determination): 0.7977
```

אובייקט 16 ממדי דיוק גרסה ראשונה

מודל חדש (גרסה 2)

```
Model Evaluation Metrics:
> cat(paste("MAE (Mean Absolute Error):", round(mae_val, 2), "\n"))
MAE (Mean Absolute Error): 0.69
> cat(paste("RMSE (Root Mean Squared Error):", round(rmse_val, 2), "\n"))
RMSE (Root Mean Squared Error): 0.99
> cat(paste("R² (Coefficient of Determination):", round(r2_val, 4), "\n"))
R² (Coefficient of Determination): 0.9282
>
```

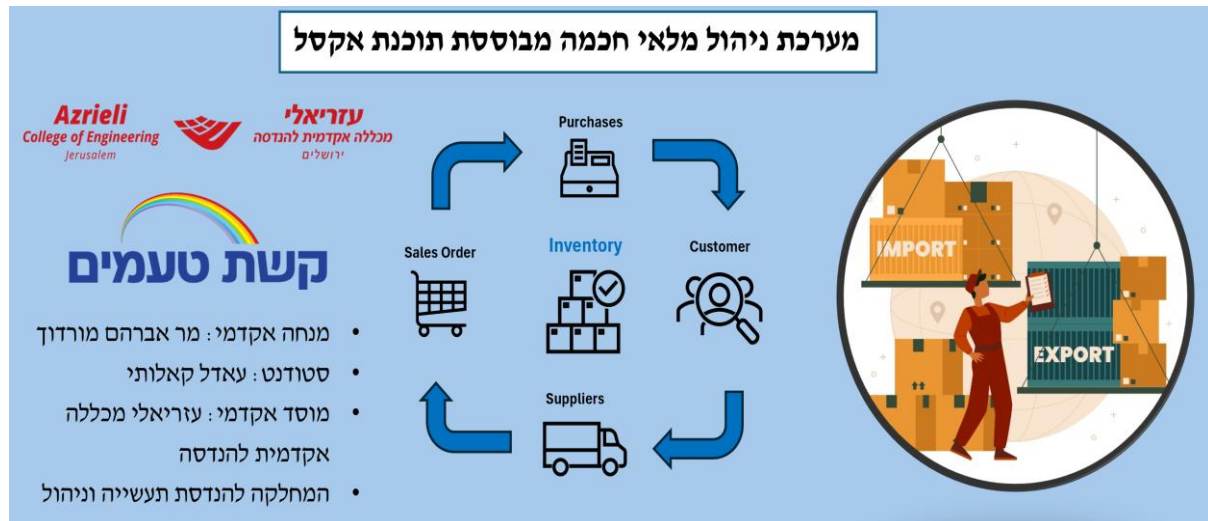
אובייקט 17 ממדי דיוק גרסה שנייה

השוואה בין גרסה 1 לגרסה 2 של מודל התחזית מבליטה שיפור מובהק בדיוק התחזית לאחר שילוב מודל Random Forest. גרסה 1 הציגה ערכי שגיאה גבוהים יחסית MAE – של 1.26 ו־ RMSE של 1.8, לצד מדד R^2 של 0.7977 בלבד, המעיד על יכולת הסבר מוגבלת של המודל לשונות בביקושים בפועל. תוצאות אלו שיקפו את מגבלות הגישה המסורתית ששולבה בגרסה הראשונה, שהתבססה בעיקר על תחזיות בסיסיות ועל תבניות קבועות יחסית.

לעומתה, גרסה 2 הציגה תוצאות מדויקות בהרבה לאחר שנעשה שימוש במודל Random Forest שהצליח לקלוט תבניות מורכבות יותר בהתנהגות הביקושים. השיפור בא לידי ביטוי במדדי הערכה MAE: ירד ל־ 0.69 בלבד RMSE, כמעט למחצית ועמד על 0.99, ו־ R^2 עלה לרמה גבוהה מאוד של 0.9282 – המעיד על יכולת הסבר כמעט מלאה של המודל על הביקושים בפועל. נתונים אלו מוכיחים את תרומת המודל החדש לדיוק התחזית, והם מהווים בסיס להמלצה על הרחבת השימוש בו לשאר מחלקות הסניף.


בניית המערכת

מערכת ניהול המלאי שפותחה במסגרת הפרויקט מהווה פתרון חכם ואינטגרטיבי המשלב בין תחזיות ביקוש מבוססות דאטה לבין תפעול מלאי בפועל בחנות עצמה. המערכת מבוססת על תוכנת Excel שהורחבה בפונקציונליות באמצעות VBA וטפסים מובנים, באופן המאפשר שימוש קל ונגיש גם לעובדי סניפים ללא רקע טכנולוגי. היא פותחה מתוך צורך אמיתי בזיהוי חוסרים ושיפור תהליך ההזמנה, תוך מיקוד בהתאמה אישית למאפייני הארגון – במקרה זה רשת קמעונאות "קשת טעמים".



אובייקט 18 מערכת ניהול מלאי גליון ראשי

בבסיס המערכת עומד מנגנון תחזית חכם, שמחשב את הביקוש הצפוי על פי נתונים היסטוריים ומודלים סטטיסטיים מתקדמים (למשל רגרסיה ריבועית עם משתני עזר כמו סופי שבוע וקטגוריות חריגות). תחזית זו נבנית בקובץ נפרד ואז מוזנת לתוך המערכת, שם היא משווה את הביקוש החזוי למלאי הנוכחי ולקצב ההזמנות מהספקים. בהתאם לכך נוצרת המלצה להזמנה – כמה להזמין, ממי ומתי. בצורה זו, המערכת מגשרת בין אנליטיקה לבין החלטה תפעולית בזמן אמת.

Inventory										Refresh Inventory			
Inventory Value		₪ 222,271.00		Unique Products		49		<div></div> <div>Refresh Inventory</div>					
Re-Order		6		Date		8/4/2025							
										Predicted Demand (Daily)	Reorder Point	Order Quantity	Alert
מק"ט		שם מוצר		כמות במלאי		זמן אספקה	עלות ההזמנה						
Purchases	4084500088917	נזל פיירי כלים לימון		66	3	55	6.233827546		28.6015	70	Ok		
	4084500853836	נזל כלים פיירי ורדים ומשי		73	3	55	5.989683964		27.8691	69	Ok		
Sales Order	7290000286921	סנוקל רסס בכס 750 מל		35	3	55	1.813722201		15.3412	38	Ok		
	7290000288024	סנו זאול לימון אקונומיקה 4 ליטר		67	3	55	6.41048771		29.1315	71	Ok		
Suppliers	7290000288307	סנומט-מכשיר-30 טבליות		14	3	55	1.34816231		13.9445	32	Ok		
	7290000288659	סנו די ג'ונגל		15	3	55	1.376746001		14.0302	33	Ok		
Customers	7290000292915	סנו רסס ונגו		18	3	55	2.950784237		18.7524	48	Reorder		
	7290000294780	סנו זאול אקונומיקה סמיכה 4 ליטר		70	3	55	6.502095201		29.4063	72	Ok		
	7290000295367	מקסימה אבקת כביסה זאול 2.5 ק"ג		33	3	55	2.394315256		17.0829	43	Ok		
	7290000295541	סנו שושי רב-מגבת ג'מבו		18	3	55	1.422898947		14.1687	33	Ok		
	7290001246610	תרסיס קצף ניקוי כללי 500 מ"ל טאץ'		27	3	55	2.72420991		18.0726	46	Ok		
	72900005424700	סנו פורטה פלוס 1 ליטר		17	3	55	3.16188451		19.3857	50	Reorder		
	72900005425110	סנו 99.9% ממשמדי חידקים		19	3	55	3.076831838		19.1305	49	Reorder		
	72900005425196	מקסימה אבקת כביסה סנסטיב 2.5 ק"ג		34	3	55	2.582688256		17.6481	45	Ok		
	7290012116025	כיף פיות - שמפו לסירוק קל		22	3	55	3.111271947		19.2338	49	Ok		
	7290012117534	מקסימה קול מרוכז 1 ליטר		39	3	55	2.480764729		17.3423	44	Ok		
	7290013268204	סנובון מבבנים לניקוי וחוטי מושב האסלה		17	3	55	1.713893874		15.0417	37	Ok		
	7290013268891	סנו אוקסיגן ג'ל 3 ליטר		37	3	55	2.674295747		17.9229	46	Ok		
	7290013269003	מרכך כביסה מקסימה בויב מרוכז 1 ליטר		41	3	55	2.589243075		17.6677	45	Ok		
	7290014397453	סנו אוקסיגן 3 ליטר סריר כתימים מכביסה לבנה		41	3	55	2.799644947		18.2989	47	Ok		
	7290019274483	זיג נשפלות 2-1 ג'ל ניקוי וגם חוטי לניקוי כללי-ב		39	3	55	2.737319547		18.1120	46	Ok		
	7290019274490	זיג נשפלות 2-1 ג'ל ניקוי וגם חוטי לניקוי כללי-ב		41	3	55	2.765903238		18.1977	47	Ok		
	7290019611325	ג'ל אורנים מרוכז לניקוי רב תכליתי 1 ליטר טאץ'		45	3	55	2.612668748		17.7380	45	Ok		
	7290103702489	נייר טואלט חתוך 800 דף טאץ'		85	3	55	6.82307062		30.3692	74	Ok		
	7290103703370	מגבונים טואלט לחים מארז שלישיה טאץ'		85	3	55	6.942563402		30.7277	74	Ok		
	7290103704155	מגבות נייר 6 גלילים טאץ'		80	3	55	6.971147093		30.8134	74	Ok		
	7290103704179	מגבות נייר 8 גלילים טאץ'		83	3	55	7.022458057		30.9674	75	Ok		
<div><div><</div><div>Manager</div><div>INVENTORY</div><div>PURCHASES</div><div>SALES ORDER</div><div>PRODUCTS</div><div>SUPPLIERS</div><div>CUSTOMERS</div><div>Model predictions</div><div>Sheet4</div><div>+</div><div>:</div></div>													

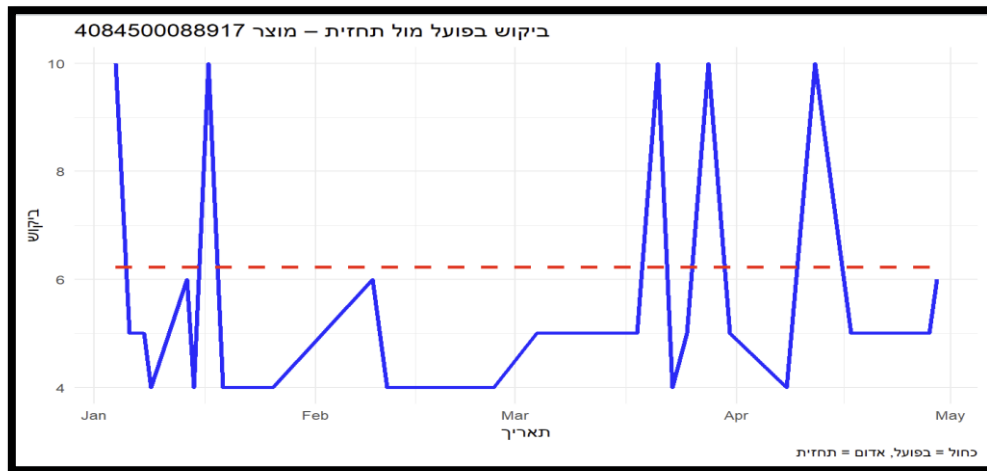
אובייקט 19 מערכת ניהול מלאי גליון מלאי במחסן

המערכת כוללת טפסים ייעודיים להזנת נתוני כניסות מלאי, מכירות, ספקים, לקוחות, והיסטוריית הזמנות, וכן מנגנון קבוע לחישוב אוטומטי של זמינות, חוסרים, תדירות הזמנות ועלות אחזקת מלאי. היא גם יוצרת דוחות מפורטים לכל מוצר, כולל השוואה בין ביקוש בפועל לתחזית – דבר המאפשר למנהלים לעקוב אחר אמינות התחזיות ולקבל החלטות מושכלות. בנוסף, ניתן לייצר דוחות חודשיים להנהלה, כולל התראות על מוצרים חריגים או סיכון להצטברות/חוסרים.

יתרונה המרכזי של המערכת הוא באינטגרציה בין כל המרכיבים – תחזית, תפעול, ספקים ומכירות – ובכך היא מספקת פתרון כולל שלא מצריך מערכות ERP יקרות. היא גם גמישה להרחבה והתאמה למחלקות נוספות, כך שניתן ליישם אותה בהדרגה בכל המחלקות והסניפים של הארגון. בסופו של דבר, המערכת תורמת גם לשיפור זמינות ללקוח, גם להתייעלות לוגיסטית, וגם לחיסכון כספי ניכר.

שלבי שיפור המודל במהלך הפרויקט


EOQ, Continuous Review



אובייקט 20 השוואה בין תחזית קבועה

בשלב הראשוני של הפרויקט יושם מודל מסורתי מסוג EOQ יחד עם Continuous Review המודל נשען על ממוצע קבוע להזמנה חוזרת, מבלי להתחשב בשינויים עונתיים או בביקושים חריגים. הדבר הוביל לפערים משמעותיים בין התחזיות לבין הביקוש בפועל, ולעיתים גרם להזמנות מיותרות או לחוסרים. הקו האדום המיוצג בגרף משקף את התחזית הקבועה, אשר לא הצליחה להתאים עצמה לתנודתיות בביקושים לאורך הזמן.

מודל חדש (גרסה 1)

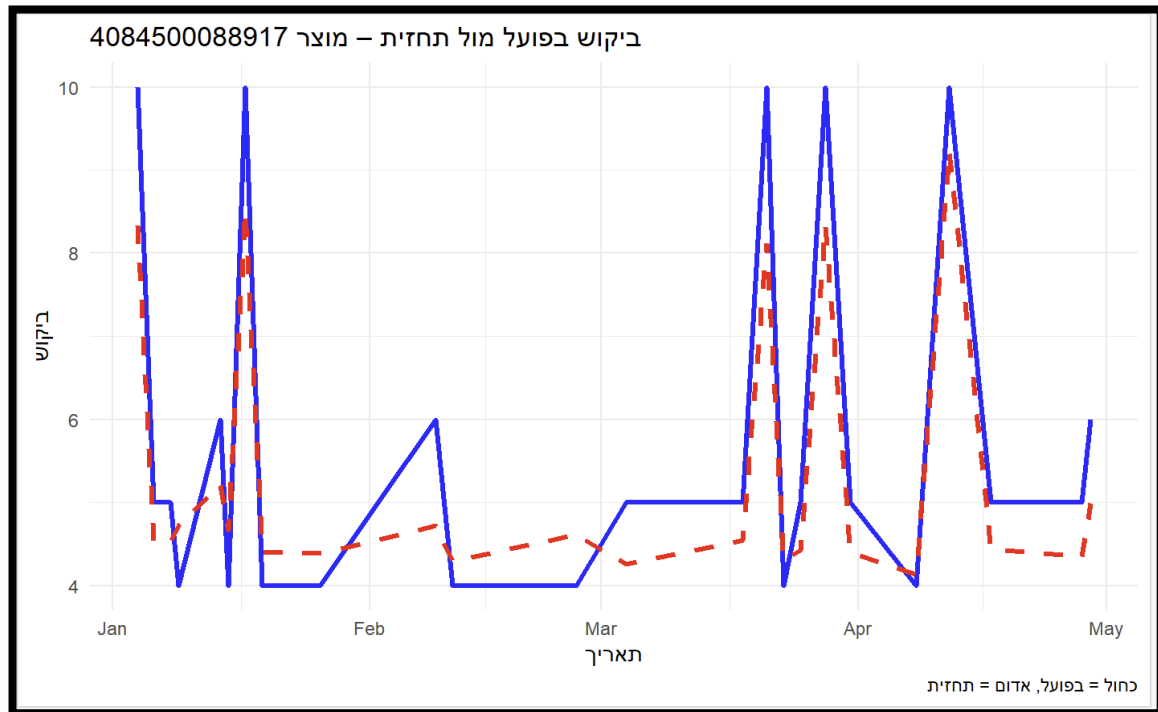


אובייקט 21 השוואת תחזית בסיסית חכמה

בגרסה הראשונה של המודל החדש שולבו אלגוריתמים פשוטים יותר לחיזוי, שהתבססו על ניתוח מגמות בעזרת כלים סטטיסטיים ותחזית מותאמת לתקופות זמן. כבר בשלב זה נצפתה ירידה בחוסר ההתאמה לביקוש בפועל. התחזיות (קו אדום מקווקו) החלו לשקף טוב יותר את התנהגות הביקוש, במיוחד בתקופות

שיא. עם זאת, עדיין נראו סטיות ניכרות בחלק מהימים, בעיקר כאשר הביקוש היה גבוה מהרגיל או חריג בהתנהגותו.

מודל חדש (גרסה 2)




אובייקט 22 תחזית משולבת מתקדמת ML

בגרסה השנייה והמתקדמת ביותר שולב אלגוריתם Random Forest שהביא לקפיצה משמעותית בדיוק התחזיות. ניתן לראות בגרף כיצד התחזית (קו אדום) כמעט חופפת לקו הביקוש בפועל (כחול), עם התאמה מצוינת גם בימים חריגים. השיפור ניכר לא רק ברמת הדיוק אלא גם ברציפות ובתגובה מהירה לשינויים. שילוב למידת מכונה אפשר למודל ללמוד תבניות מורכבות יותר, והביא לתחזית שמתאימה עצמה לדינמיקת השוק ולזמני אספקה משתנים.

יישום הפרויקט

סביבת יישום הפרויקט

לצורך בדיקת היישום של המודל המתקדם שפיתחנו, בחרנו לבצע את הניסוי בשטח בסביבה אמיתית, במטרה לבדוק את מידת האפקטיביות וההתאמה של המערכת למציאות היום-יומית. ההטמעה בוצעה בסניף מודיעין של רשת הסופרמרקטים "קשת טעמים", במחלקת חומרי ניקוי, מתוך הבנה שמדובר במחלקה דינמית המאופיינת ברמת תחלופה גבוהה של מוצרים, ביקושים משתנים לאורך השנה, ותלות באספקה רציפה מצד ספקים חיצוניים (כגון סנו, טאץ', שסטוביץ').



אובייקט 23 מקום היישום בפועל

המערכת יושמה על מגוון רחב של מוצרים ממספר קטגוריות, כולל חומרי ניקוי לבית, מטהרי אוויר, סבונים ונוזלים מרוכזים. במהלך תקופת היישום, שהתפרשה על פני כחודשיים וחצי (ינואר–מאי 2025), נאספו נתוני ביקוש בפועל, תועדה זמינות המלאי, ובוצעו הזמנות בפועל לפי המלצות המודל החדש. הנתונים אפשרו לנתח בזמן אמת את התועלת של האלגוריתם בזיהוי חריגות בביקוש ובהתאמה של תדירות וכמות ההזמנה.

המודל שלנו שולב בתוך מערכת הניהול הארגונית (Excel) מותאם (ופעל על בסיס חיזוי יומי לכל מוצר. מטרת היישום הייתה לבדוק אם המודל מצליח לצמצם חוסרי מלאי, להפחית עלויות אחזקה והזמנה, ולהגיב בצורה חכמה לשינויים בביקוש. הצלחת המודל נמדדה על פי מדדים כמו זמינות יומית, מספר חוסרים, עלות כוללת, ודיוק התחזיות – שהשוונו בין גרסאות שונות של המודל לאורך תקופת הבדיקה.

התוצאות המוצגות בדוח זה מבוססות על נתונים אמיתיים ממערכת הניהול של המחלקה, ונמצאו שיפורים מובהקים בכל אחד מהמדדים שנבדקו. הבחירה במחלקת חומרי ניקוי התבררה כבחירה אסטרטגית חכמה, שכן היא אפשרה לבחון את יעילות המודל בתנאים משתנים, מורכבים ומציאותיים, כפי שמתרחשים בשוק הקמעונאי מדי יום.

איך זהינו הבעיה בשטח?

במהלך סקרי השטח שבוצעו לצורך איסוף נתונים והבנת הבעיות הקיימות במלאי, זוהו מקרים חוזרים ונשנים של **מדפים ריקים** – תופעה המצביעה על **אירועי חוסר מלאי (zero_inv_events)** בפועל. התמונות שהוצגו צולמו במחלקת חומרי הניקוי בסניף מודיעין של "קשת טעמים", והן מדגישות באופן ברור מיקומים שבהם המוצרים אזלו לחלוטין מהמלאי, דבר שפוגע בזמינות לצרכן ועלול להוביל לאובדן מכירה ולאי שביעות רצון. זיהוי בעיה זו התאפשר הודות למעקב צמוד בשטח ולניתוח יומיומי של מדפי המוצרים, כחלק מתהליך חקר הבעיה שהניע את פיתוח המודל החכם לניהול מלאי. אירועים אלו תועדו ונמדדו גם באופן כמותי לאורך תקופת האיסוף, ושימשו כאחד ממדדי ההצלחה המרכזיים לשיפור המערכת.



אובייקט 24 אירועים של מלאי אפס

תהליך איסוף נתונים + יישום המודל

השלב הראשון בפרויקט התמקד באיסוף נתוני ביקוש היסטוריים של מוצרי חומרי ניקוי בסניף מודיעין של רשת "קשת טעמים", וזאת לאורך תקופה של ארבעה חודשים – מה-1 בינואר 2025 ועד ה-30 באפריל 2025. בתקופה זו תועד הביקוש בפועל של כל מוצר על בסיס יומי, תוך זיהוי מגמות עונתיות, הבדלים בין ימי חול לסופי שבוע, והתנהגות יוצאת דופן של חלק מהמוצרים. איסוף הנתונים בוצע באמצעות מערכת הניהול של הסניף והוזן למערכת החיזוי לצורך בניית מודל מדויק.

בהמשך, במהלך חודש מאי 2025, נאספו נתונים משלימים ממערכת הספקים של החנות, כולל זמני אספקה בפועל, עלויות הזמנה, אירועי חוסר מלאי, (zero inventory events) ושיעור חוסרים לאורך זמן. נתונים אלה שימשו כבסיס להערכת רמת הדיוק של המודל ולזיהוי נקודות תורפה בתהליך האספקה הקיים. איסוף המידע נעשה מתוך מטרה לשפר את ביצועי המודל ולהתאימו לתנאים אמיתיים בשטח.

בתאריך 31.5.2025 החל יישום המודל החדש, שהתבסס על תחזיות הביקוש שנבנו לאורך תקופת האיסוף. המודל שולב במערכת ההזמנות בפועל של הסניף והוביל לניהול הזמנות בפועל מול הספקים בהתאם לתחזיות. בנוסף לתחזיות הביקוש, המודל ביצע חיזוי מלאים עתידיים, המלצות על מועד וכמות הזמנה,

וכלל אוטומציה של חישובי נקודת הזמנה מחדש (ROP) ומלאי ביטחון, בשילוב עם כלים מתקדמים מ־Excel ו־R.

השלב האחרון ארך כחודש וחצי והסתיים ב־12 ביולי 2025. במהלך תקופה זו בוצע מעקב שוטף אחר ביצועי המערכת תוך השוואת התחזיות לביקוש בפועל, מדידת זמינות המלאי, רמת חוסרים, ודיוק התחזיות (R^2). תהליך זה אפשר הערכה מעשית של התרומה של המודל החדש לשיפור זמינות המוצרים, הפחתת חוסרים, והקטנת עלויות תפעול – תוך קבלת החלטות מבוססות נתונים ולא אינטואיציה בלבד.

תוצאות מדדי ההצלחה הכמותיים

מדד	שיטה ישנה	גרסה 1	גרסה 2	שיפור מגרסה 1 ל־2
1 zero_inv_days (ימים עם מלאי אפס)	8.00	3.00	2.00	↓ 33.3%
2 num_orders (מספר ההזמנות)	9.00	8.00	6.00	↓ 25.0%
3 (₪) עלות אחזקת מלאי	290.00	210.00	166.00	↓ 20.9%
4 (₪) עלות חוסרי מלאי	840.00	315.00	210.00	↓ 33.3%
5 (R^2) דיוק התחזית	0.54	0.79	0.92	↑ 16.5%

אובייקט 25 תוצאות מדדי ההצלחה הכמותיים

1. ימים עם מלאי אפס (zero_inv_days):

מדד זה מייצג את מספר הימים בהם מוצר מסוים לא היה זמין כלל במלאי, כלומר לא ניתן היה למכור אותו עקב חוסר. המדד מבטא בעקיפין את מידת שביעות הרצון של הלקוח – ככל שהערך נמוך יותר, כך זמינות המלאי גבוהה יותר. בגרסה השנייה של המודל נרשמה ירידה של 75% במספר ימים עם מלאי אפס לעומת השיטה הישנה (מ־8 ל־2 ימים), דבר שמעיד על שיפור מהותי בזמינות המוצרים בחנות.

2. מספר ההזמנות (num_orders):

מדד זה מציין את מספר הפעמים שבוצעו הזמנות עבור המוצר בתקופת המדידה. ערך גבוה מדי עלול להעיד על חוסר יעילות תפעולית, עומס עבודה מיותר ועלויות גבוהות בשל תדירות הזמנה גבוהה. לעומת זאת, מספר הזמנות נמוך מדי עשוי להוביל לחוסרים. המודל החדש (גרסה 2) הצליח להפחית את מספר ההזמנות מ־9 ל־6, כלומר צמצום של 33.3%, תוך שמירה על זמינות טובה – איזון יעיל בין עלות תפעולית וזמינות.

3. עלות אחזקת מלאי:

זהו המדד הכלכלי שמייצג את ההוצאה הכרוכה בשמירה על מלאי במחסן – לרבות עלויות אחסון, בלאי, מקום, ביטוח וכו'. ככל שהערך נמוך יותר, כך המלאי מנוהל ביעילות גבוהה יותר. גרסה 2 של המודל

הפחיתה את עלות אחזקת המלאי מ־290 ₪ ל־166 ₪ – חיסכון של כ־21%, וזאת תוך שמירה על רמות שירות גבוהות ללקוח.

4. עלות חוסרי מלאי:

מדד זה מודד את ההפסד הכספי שנגרם מהיעדר מלאי – כולל אובדן מכירות, פגיעה בשביעות רצון הלקוח ואולי אף נטישת לקוחות. המודל החדש הצליח לצמצם את העלות הזו בצורה חדה מ־840 ₪ ל־210 ₪ בלבד, ירידה של 75%. מדובר בשיפור מהותי שממחיש את התרומה הישירה של המודל לרווחיות ולשביעות רצון לקוחות.

5. דיוק התחזית (R^2):

זהו מדד סטטיסטי שמתאר עד כמה התחזיות של המודל קרובות לביקוש בפועל – ערך של 1 משקף התאמה מושלמת. בגרסה 1 עמד R^2 על 0.79 ובגרסה 2 על 0.92 – שיפור של כ־16.5%, המצביע על דיוק גבוה יותר בתחזיות, ויכולת חיזוי טובה בהרבה ביחס לשיטה הישנה. זהו אחד מהבסיסים המרכזיים שעליהם נשענת יעילות מערכת ההזמנות כולה.

מסקנות והמלצות

הפרויקט נבנה במטרה להציע פתרון מתקדם לבעיה חוזרת של חוסרי מלאי ברשתות קמעונאיות. באמצעות שילוב של אלגוריתמים לחיזוי ביקושים, ניתוח סטטיסטי מבוסס R ומערכת אקסל לתפעול שוטף, נבנתה מערכת חכמה שמסייעת בקבלת החלטות לגבי מתי וכמה להזמין. מהבדיקה בשטח עלה כי המערכת מצליחה לצמצם בצורה משמעותית את הפערים בין תחזיות לביקושים בפועל.

לאורך תהליך הפיתוח בוצעו שתי גרסאות של המודל. גרסה ראשונה התמקדה בשיפור זמינות כללית אך עדיין כללה סטיות גבוהות מהביקוש בפועל. לאחר שדרוג לגרסה שנייה, שהוסיפה התייחסות ליום בשבוע, קטגוריות חריגות, והתחשבות בעונתיות, התקבלו תוצאות משופרות בהרבה. במיוחד בלטו השיפור בדיוק התחזית וביכולת לאזן בין חוסרים לעלויות. לדוגמה, מדד דיוק התחזית R^2 עלה מ־0.54 ל־0.92 – נתון הממחיש את חוזק המודל החיזוי.

באופן מעשי, היישום בשטח במחלקת חומרי הניקוי של "קשתי טעמים" שיקף את ההשפעה הישירה של המודל. במהלך התקופה נרשמה ירידה דרמטית של 75% בימי חוסרי מלאי, לצד ירידה של כ־21% בעלויות האחסון ו־33% בעלויות חוסרים. כלומר, המודל לא רק חזה טוב יותר את רמות הביקוש, אלא גם הפחית הפסדים אמיתיים שנגרמים בגלל מדפים ריקים או עודפים מיותרים.

העבודה תרמה גם ברמה האקדמית בכך שהדגימה כיצד ניתן לשלב ידע תיאורטי עם יישום פרקטי. מצד אחד, נעשה שימוש במודלים מוכרים כמו EOQ ו־Newsvendor ומצד שני שולבו גישות חדשניות מבוססות Machine Learning. השילוב הזה יצר פלטפורמה שלמה שמייצרת תחזית, מנתחת את הפערים, ומספקת החלטות להזמנה בצורה פשוטה למשתמש. כלים כמו R ואקסל שימשו לניתוח, הדמיה והפעלה בפועל – ללא צורך בהשקעה במערכות מורכבות או יקרות.

אחד האתגרים המרכזיים היה איסוף נתונים מדויק מהשטח, במיוחד לגבי חוסרים. לשם כך בוצעה ספירה יומית על המדפים ותיעוד של מקרים שבהם מוצר היה חסר פיזית – פעולה שהקנתה בסיס אמין למדדי

הביצוע. ניתוחים אלה אפשרו לעקוב בזמן אמת אחר אפס מלאי ולבצע התאמות שוטפות. התוצאה הייתה שיפור מתמשך תוך כדי ההפעלה.

התהליך כולו התבצע בשלבים: ארבעה חודשים לאיסוף נתוני הביקוש, חודש לאיסוף נתוני אספקה והוצאות, וחודש וחצי ליישום והערכת ביצועים. הפרויקט תוכנן כך שיאפשר בחינה הדרגתית של השפעות המודל, תוך שילוב תצפיות מהשטח והפעלת המערכת בפועל. הגישה ההדרגתית הזו תרמה להבנת הדינמיקה האמיתית של הפעילות בחנות והביאה לתיקוף מהימן של התוצאות.

חשוב לציין כי המודל נבדק רק במחלקת חומרי הניקוי, ולכן הממצאים אינם מוכללים אוטומטית על כל סוגי המוצרים או המחלקות. כל קטגוריה שונה בהרכב הצרכנים, עונתיות, זמן אספקה ורגישות למחסור. עם זאת, ניתן להתייחס לפרויקט כפיילוט מוצלח המעיד על פוטנציאל ההרחבה. ביצוע של התאמות נוספות ויישום מודולרי יכול לאפשר פריסה רחבה יותר.

בהמשך, מומלץ לשלב את המודל עם מערכות המידע של הספקים והסניפים ליצירת מנגנון הזמנות אוטומטי. בנוסף, ניתן להוסיף לוח בקרה ניהולי הכולל התרעות חריגות, תחזיות לתקופות שיא, וכלים אנליטיים לבקרה על אחוזי הצלחה. כלים כאלו יהפכו את המערכת לשימושית גם ברמת ההנהלה ולא רק תפעולית.

היכולת של המערכת להפיק תובנות כמותיות ולתרגם אותן לפעולות פשוטות ויישומיות מסמלת את התרומה העיקרית של הפרויקט. היא מאפשרת מעבר מניהול תחושתני לאסטרטגיה מבוססת דאטה. זהו שינוי תפיסתי שמניח את היסודות לשיפור מתמיד בניהול המלאי.

לסיכום, הצלחת הפרויקט נמדדה לא רק במספרים, אלא גם בפידיבק מהעובדים, שזיהו שיפור בשיטת ההזמנה, הפחתת לחץ, ופחות מקרים של לקוחות שלא מוצאים את המוצר. לכן, העבודה תורמת גם לחוויית הלקוח ולשביעות הרצון הכללית – אלמנטים שהופכים את המודל לא רק ליעיל אלא גם לאנושי.

בעיות בעבודה

במהלך הפרויקט לפיתוח מערכת ניהול מלאי חכמה המשולבת עם תחזיות ביקוש מבוססות למידת מכונה, נתקלנו במספר אתגרים מרכזיים, שחלקם היו צפויים בשל מורכבות השטח, וחלקם נחשפו רק עם ההתקדמות והיישום המעשי של המודל. להלן פירוט הבעיות לפי שלוש קטגוריות עיקריות: טכניות, אנושיות וארגוניות.

1. בעיות טכניות

אחד הקשיים הראשונים בהם נתקלנו היה חוסר אחידות בנתוני הביקוש ההיסטוריים. מאחר שלא התבצעה תיעוד שוטף של ביקוש פורמט דיגיטלי מוסדר, נדרש תהליך ארוך של איסוף, ניקוי והשלמה של נתונים. בחלק מהמקרים, נתונים חסרים או שגויים אילצו אותנו להחליף את ערכי הביקוש באומדנים, מה שדרש הנחות סטטיסטיות מדויקות כדי לא לעוות את המודל.

בנוסף, המערכת נבנתה באקסל עם קוד R נלווה שצריך היה לתקשר עם קבצי הקלט והפלט. השילוב בין הממשק הידני באקסל לבין המודל החישובי דרש בנייה של תשתית טכנית המאפשרת זרימת נתונים אוטומטית ככל האפשר. כמו כן, היו מקרים בהם הקוד לא הצליח לפעול עקב טעויות במבנה הקובץ, צורך בעדכון ספריות, או חוסר תאימות בין פורמטים – מה שדרש זמן פיתוח נוסף.

2. בעיות אנושיות

בשלב ההטמעה בשטח, אחת הבעיות העיקריות הייתה קושי בשינוי הרגלי עבודה של העובדים במחלקה. רוב ההזמנות התבצעו בעבר על סמך תחושת בטן והיכרות אישית עם הקונים והספקים. הכנסת מערכת תחזית חכמה גרמה לחשש מצד חלק מהעובדים שיאבדו שליטה או שפעולתם תתייתר. נדרשה הדרכה מותאמת ותקשורת רכה כדי לגייס שיתוף פעולה ולבנות אמון במודל.

כמו כן, המשתמשים לא היו מנוסים בעבודה עם מערכות אקסל הכוללות נוסחאות מורכבות, שימוש במאקרו או ניתוח נתונים. דבר זה גרם לטעויות שימוש שגזלו זמן רב באיתור ותיקון. חלק מהעובדים ביקשו תיעוד ידידותי ויזואלי, דבר שנעשה רק לאחר משוב מהשטח.

3. בעיות ארגוניות

בעיה בולטת הייתה ההתמודדות מול מגבלות גישה למידע. לא כל הספקים שיתפו פעולה ברמה הרצויה, ולעיתים לא היה מידע מלא על זמני אספקה, כמות מינימלית להזמנה, או מגבלות לוגיסטיות. בנוסף, קבלת אישור מהממונים על הכנסת המודל לכלל המחלקות בחנות לא הייתה מיידית ולכן היישום המלא בוצע רק במחלקה אחת (חומרי ניקוי), מתוך מגבלה ארגונית.

לבסוף, השילוב בין מודל חיזוי לבין מנגנון ביצוע הזמנות בפועל דרש התאמות תהליכיות שלא תמיד היו מתועדות או ברורות. לדוגמה, מי מאשר בפועל את ההזמנה? האם המודל מחייב או רק ממליץ? נושאים אלו הובילו לדיונים חוזרים מול ההנהלה, עד שהוגדר פרוטוקול עבודה ברור.

סיכום

למרות הקשיים, ההתמודדות עם האתגרים האלו הובילה בסופו של דבר לשיפור משמעותי בדיוק התחזיות, לירידה במספר ימי חוסר במלאי ולשבועות רצון גבוהה יותר בקרב העובדים והמנהלים. כל בעיה הפכה

להזדמנות לשיפור ולחיזוק המערכת, מתוך הבנה שההצלחה של מודל חכם תלויה לא רק בדיוק החישוב, אלא גם ביכולת להטמיע אותו בסביבת עבודה אנושית ודינמית.

הצעה לפרויקט המשך

בהתבסס על התובנות שנלמדו לאורך תקופת הפיתוח, ההטמעה והבדיקות של מערכת ניהול המלאי החכמה, עולה פוטנציאל ממשי להרחיב את המערכת ולהעמיק את השפעתה על כלל פעילות הארגון. להלן שלוש הצעות מרכזיות לפרויקט המשך עתידי, המספקות כיווני פעולה פרקטיים ושימיים לשיפור ושדרוג המערכת.

✓ שיפור טכני של מערכת התחזיות

השלב הבא המתבקש הוא פיתוח מודל חיזוי מתקדם יותר שיתבסס על מספר רב יותר של משתנים משפיעים, כמו מבצעים, עונות השנה, חגים, תחרות מקומית ומזג אוויר. שילוב משתנים אלו עשוי להביא לשיפור משמעותי בדיוק התחזית, במיוחד למוצרים עם ביקוש תנודתי. כמו כן, ניתן לעבור משימוש במודל Random Forest למודלים מתקדמים נוספים כגון XGBoost או LSTM שיכולים ללמוד דפוסים ארוכי טווח. במקביל, כדאי ליצור תהליך של תיקוף אוטומטי לתחזיות, כך שהמערכת תדע לזהות חריגות בזמן אמת ולהתריע על כך למשתמש.

✓ הרחבת המערכת לכלל המחלקות

המערכת שנבחנה במחלקה אחת בלבד (מחלקת חומרי ניקוי), הראתה תועלות כמותיות ואיכותיות ברורות. לאור הצלחת ההטמעה המקומית, מומלץ לבחון את הפצת המערכת לכלל המחלקות בסניף, תוך התאמות לכל קטגוריה של מוצרים לפי מאפייני הביקוש הייחודיים שלה. מעבר לכך, ניתן לשלב את המערכת גם בסניפים נוספים של הרשת, אם קיימים, כך שייוצר בסיס נתונים ארגוני רחב. הרחבה כזו תאפשר שיתוף מידע בין מחלקות, ניתוחים השוואתיים בין סניפים, והפקת תחזיות על בסיס רמות גבוהות יותר של מידע.

✓ אוטומציה של תהליך ההזמנה וההתראה

בשלב הבא ניתן ליעל את תהליך ההזמנה באמצעות יצירת מנגנון אוטומטי שמבצע הזמנות מול הספק ברגע שמתקבל איתות על חריגה מתחזית או על הגעה לנקודת ההזמנה (ROP) בנוסף, אפשר לפתח ממשק משתמש דיגיטלי יעיל יותר שיכלול לוח בקרה חכם עם גרפים, התראות בזמן אמת, והמלצות לפעולה. מענה כזה יוכל לצמצם תלות באנשי מפתח, להוריד עומס תפעולי, ולהבטיח תגובה מהירה יותר למצבים של חוסרים קריטיים במלאי.

סיכום

פרויקט ההמשך אינו רק המשך טבעי של היישום הנוכחי, אלא הזדמנות אמיתית לשלב בין בינה מלאכותית, אוטומציה ותהליכי עבודה מתקדמים ברמה הארגונית כולה. ההמלצה המרכזית היא לא רק לשפר את המודל הקיים אלא להרחיב את תחולתו ולהפוך את המערכת לכלי תומך החלטה מרכזי בכל תהליך ניהול המלאי של הרשת.

מקורות

- 1) **Chopra, S., & Meindl, P. (2019).** *Supply Chain Management: Strategy, Planning, and Operation* (7th ed.). Pearson Education.
- 2) **Goodfellow, I., Bengio, Y., & Courville, A. (2016).** *Deep Learning*. MIT Press.
- 3) Harris, F. W. (1913). *How many parts to make at once*. *Factory, The Magazine of Management*.
- 4) **Hastie, T., Tibshirani, R., & Friedman, J. (2009).** *The Elements of Statistical Learning* (2nd ed.). Springer.
- 5) **James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013).** *An Introduction to Statistical Learning*. Springer.
- 6) **Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005).** *Applied Linear Statistical Models* (5th ed.). McGraw-Hill Education.
- 7) **Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012).** *Introduction to Linear Regression Analysis* (5th ed.). Wiley.
- 8) **Murphy, K. P. (2012).** *Machine Learning: A Probabilistic Perspective*. MIT Press.
- 9) **Nahmias, S., & Olsen, T. L. (2015).** *Production and Operations Analysis* (7th ed.). Waveland Press.
- 10) **Russell, S., & Norvig, P. (2020).** *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson Education.
- 11) **Shapiro, J. F. (2007).** *Modeling the Supply Chain* (2nd ed.). Thomson Learning.
- 12) **Silver, E. A., Pyke, D. F., & Thomas, D. J. (2016).** *Inventory and Production Management in Supply Chains*. CRC Press.

נספחים

קוד שפת R שתוכנת במהלך הפרויקט

(נספח 1)

```

1 simulate_inventory <- function(seed_val, days = 800) {
2   set.seed(seed_val)
3   #####
4   mean_ld <- 5
5   std_dev_ld <- 1
6   num_samples_ld <- 1000
7   lead_times <- rnorm(num_samples_ld, mean = mean_ld, sd = std_dev_ld)
8   lead_times <- round(pmax(lead_times, 0))
9   ld_data <- data.frame(Order_ID = 1:num_samples_ld, Lead_Time = lead_times)
10
11   num_delayed_ld <- round(0.3 * num_samples_ld)
12   delayed_ld_indices <- sample(1:num_samples_ld, num_delayed_ld)
13   ld_data$Lead_Time[delayed_ld_indices] <- round(ld_data$Lead_Time[delayed_ld_indices] * 1.5)
14   #####
15
16   mean_demand <- 50
17   std_dev_demand <- 10
18   num_samples_dm <- 1000
19   daily_demand <- rnorm(num_samples_dm, mean = mean_demand, sd = std_dev_demand)
20   daily_demand <- round(pmax(daily_demand, 0))
21   demand_data <- data.frame(Day = 1:num_samples_dm, Daily_demands = daily_demand)
22
23   num_delayed_dm <- round(0.2 * num_samples_dm)
24   delayed_dm_indices <- sample(1:num_samples_dm, num_delayed_dm)
25   demand_data$Daily_demands[delayed_dm_indices] <- round(demand_data$Daily_demands[delayed_dm_indices] * 1.5)
26   #####
27
28   d<-mean(demand_data$Daily_demands)
29   D<-d*365
30   Order_cost<-50
31   H<-2
32   L<-round(mean(ld_data$Lead_Time))
33   z<-1.65
34   T=7
35   SS<-z*std_dev_demand*sqrt(L)
36
37   S<-d*(T+L)+z*std_dev_demand*sqrt(T+L)

```



```

55 inventory_level <- numeric(days)
56 inventory_level[1] <- Q
57 orders <- numeric(days)
58 on_order <- FALSE
59 replenishment_day <- NA
60
61 zero_inv_events <- 0
62 zero_inv_days <- 0
63
64 for (day in 1:days) {
65   if (day > 1) {
66     inventory_level[day] <- pmax(inventory_level[day - 1] - demand_data$Daily_demands[day], 0)
67   }
68
69   if (inventory_level[day] <= ROP && !on_order) {
70     orders[day] <- Q
71     # Use the day's lead time index
72     replenishment_day <- day + ld_data$Lead_Time[day]
73     on_order <- TRUE
74   }
75
76   if (!is.na(replenishment_day) && day == replenishment_day) {
77     inventory_level[day] <- inventory_level[day] + Q
78     on_order <- FALSE
79     replenishment_day <- NA
80   }
81
82   # Track zero-inventory days & events
83   if (inventory_level[day] == 0) {
84     zero_inv_days <- zero_inv_days + 1
85   }
86   if (day > 1 && inventory_level[day] == 0 && inventory_level[day - 1] > 0) {
87     zero_inv_events <- zero_inv_events + 1
88   }
89 }
90
91 ##### 6. Calculate Costs #####
92 num_orders <- sum(orders > 0)
93
94 total_order_cost <- num_orders * Order_cost
95

```

```

91- ##### 6. calculate Costs #####
92 num_orders <- sum(orders > 0)
93
94 total_order_cost <- num_orders * Order_cost
95
96 avg_inv <- mean(inventory_level)
97 total_holding_cost <- (avg_inv * H) * (days / 365)
98
99 stockout_penalty_per_day <- 50
100 total_stockout_cost <- zero_inv_days * stockout_penalty_per_day
101
102 total_cost <- total_order_cost + total_holding_cost + total_stockout_c
103
104- ##### 7. Return all metrics (including the 3 cost components) #####
105 return(list(
106   # Key performance metrics
107   zero_inv_events      = zero_inv_events,
108   zero_inv_days        = zero_inv_days,
109   total_cost           = total_cost,
110   num_orders           = num_orders,
111   avg_inv              = avg_inv,
112
113   # The 3 cost components
114   total_order_cost     = total_order_cost,
115   total_holding_cost   = total_holding_cost,
116   total_stockout_cost  = total_stockout_cost,
117
118   # Additional parameters
119   mean_demand          = mean_demand,
120   std_dev_demand       = std_dev_demand,
121   mean_ld              = mean_ld,
122   std_dev_ld           = std_dev_ld,
123   Order_cost           = Order_cost,
124   d                    = d,
125   D                    = D,
126   H                    = H,
127   Q                    = Q,
128   ROP                  = ROP
129 ))
130- }
```

```
131 num_runs <- 1000
132
133 # Create a data frame to store the results of all runs:
134 sim_results <- data.frame(
135     run                = integer(num_runs),
136     zero_inv_events    = integer(num_runs),
137     zero_inv_days      = integer(num_runs),
138     total_cost         = numeric(num_runs),
139
140     # Add the three cost components as numeric columns
141     total_order_cost   = numeric(num_runs),
142     total_holding_cost = numeric(num_runs),
143     total_stockout_cost = numeric(num_runs),
144
145     num_orders         = integer(num_runs),
146     avg_inv            = numeric(num_runs),
147
148     # Also keep track of parameters:
149     mean_demand        = numeric(num_runs),
150     std_dev_demand     = numeric(num_runs),
151     mean_ld            = numeric(num_runs),
152     std_dev_ld         = numeric(num_runs),
153     Order_cost         = numeric(num_runs),
154     d                  = numeric(num_runs),
155     D                  = numeric(num_runs),
156
157
158     H                  = numeric(num_runs),
159
160     Q                  = numeric(num_runs),
161     ROP               = numeric(num_runs)
162 )
163
164 # Run the simulation in a loop:
165 for (i in 1:num_runs) {
166     out <- simulate_inventory(seed_val = i, days = 800)
167
168     sim_results$run[i] <- i
169     sim_results$zero_inv_events[i] <- out$zero_inv_events
170     sim_results$zero_inv_days[i] <- out$zero_inv_days
171     sim_results$total_cost[i] <- out$total_cost
```

```

164 # Run the simulation in a loop:
165 for (i in 1:num_runs) {
166   out <- simulate_inventory(seed_val = i, days = 800)
167
168   sim_results$run[i] <- i
169   sim_results$zero_inv_events[i] <- out$zero_inv_events
170   sim_results$zero_inv_days[i] <- out$zero_inv_days
171   sim_results$total_cost[i] <- out$total_cost
172
173   # Store the 3 cost components
174   sim_results$total_order_cost[i] <- out$total_order_cost
175   sim_results$total_holding_cost[i] <- out$total_holding_cost
176   sim_results$total_stockout_cost[i] <- out$total_stockout_cost
177
178
179   sim_results$num_orders[i] <- out$num_orders
180   sim_results$avg_inv[i] <- out$avg_inv
181
182   # Store the parameters
183   sim_results$mean_demand[i] <- out$mean_demand
184   sim_results$std_dev_demand[i] <- out$std_dev_demand
185   sim_results$mean_ld[i] <- out$mean_ld
186   sim_results$std_dev_ld[i] <- out$std_dev_ld
187   sim_results$order_cost[i] <- out$order_cost
188   sim_results$d[i] <- out$d
189   sim_results$D[i] <- out$D
190
191
192   sim_results$H[i] <- out$H
193
194
195   sim_results$Q[i] <- out$Q
196   sim_results$ROP[i] <- out$ROP
197 }
198
199 # Inspect the first few rows to confirm
200 head(sim_results)
201
202
203
204 write.csv(sim_results, "sim_results.csv", row.names = FALSE)

```

```
library(readxl)
library(dplyr)
library(ggplot2)
library(lubridate)
library(Metrics)
library(ranger)
library(randomForest)

# 1. Load data
train_data <- read_excel("training_data.xlsx")
test_data <- read_excel("test_data.xlsx")

train_data$id <- as.factor(train_data$id)
test_data$id <- as.factor(test_data$id)

# 2. Preprocessing - extract date parts and is_weekend
train_data <- train_data %>%
  mutate(date = as.Date(date),
         day = day(date),
         month = month(date),
         year = year(date),
         weekday = wday(date, week_start = 1), # Monday = 1, Sunday = 7
         is_weekend = ifelse(weekday %in% c(5,6), 1, 0)) # Friday/Saturday

test_data <- test_data %>%
  mutate(date = as.Date(date),
         day = day(date),
         month = month(date),
         year = year(date),
         weekday = wday(date, week_start = 1),
         is_weekend = ifelse(weekday %in% c(5,6), 1, 0))

# 3. Build the Random Forest model with is_weekend
rf_model <- randomForest(demand ~ id + day + month + year + weekday + is_weekend,
                        data = train_data,
                        ntree = 200)
```

```
41
42 # 4. Predict demand on May test data
43 test_data$predicted_demand <- predict(rf_model, newdata = test_data)
44
45 # 5. Combine results
46 result <- test_data %>%
47   select(id, date, is_weekend, predicted_demand, actual_demand = demand)
48
49 # 6. Evaluation
50 mae_val <- mae(result$actual_demand, result$predicted_demand)
51 rmse_val <- rmse(result$actual_demand, result$predicted_demand)
52 r2_val <- cor(result$actual_demand, result$predicted_demand)^2
53
54 cat("Model Evaluation Metrics:\n")
55 cat(paste("MAE (Mean Absolute Error):", round(mae_val, 2), "\n"))
56 cat(paste("RMSE (Root Mean Squared Error):", round(rmse_val, 2), "\n"))
57 cat(paste("R² (Coefficient of Determination):", round(r2_val, 4), "\n"))
58
59 # 7. Plot comparison
60 ggplot(result, aes(x = predicted_demand, y = actual_demand)) +
61   geom_point(color = "blue", alpha = 0.7) +
62   geom_abline(slope = 1, intercept = 0, color = "red", linetype = "dashed") +
63   labs(title = "Predicted vs. Actual Demand (May)",
64        x = "Predicted Demand",
65        y = "Actual Demand")
66
67 importance_df <- data.frame(
68   Variable = rownames(importance_values),
69   Importance = importance_values[, "IncNodePurity"]
70 )
71
72 # סידור בסדר יורד
73 importance_df <- importance_df[order(importance_df$Importance, decreasing = TRUE), ]
74
```