

מטרת הפרויקט

פיתוח ויישום מערכת חכמה לניהול מלאי, המבוססת על מודל למידת מכונה, לצורך שיפור זמינות המוצרים, הקטנת חוסרים, והתייעלות בתהליך קבלת ההחלטות ברכש.

מדדי הצלחה כמותיים



סביבת יישום הפרויקט

חברת קשת טעמים (מודיעין) – מחלקת חומרי ניקוי

קשת טעמים


בתקופת היישום ההזמנות בוצעו על ידי מול ספקים של חומרי ניקוי בארץ: סנו, טאץ', שסטוביץ

1. המודל יושם על מספר רב של מוצרים של חומרי ניקוי כדי לזהות דפוסי הביקוש של המוצרים וגם להימנע חוסרים במלאי


2. כדי למדוד הצלחת הפרויקט בצורה אמיתית, בחרנו ליישם הפרויקט בסביבת עבודה אמיתית בפועל (מחסנים של החברה)

שלבי שיפור מודל ML במהלך הפרויקט

מודל חדש (גרסה 1)



מודל חדש (גרסה 2)



הבעיה המרכזית

טעויות בקביעת הפרמטרים Q^* , ROP גורמות ל:

חוסרים במלאי

פגיעה בשביעות רצון הלקוחות ואובדן הכנסות.

מלאי עודף

בזבוז משאבים, עלויות אחסנה גבוהות ופגיעה ברווחיות

הבעיה המרכזית

האתגר המרכזי בניהול מלאי הוא לקבוע באופן מדויק שני פרמטרים קריטיים:

כמה להזמין?
(כמות ההזמנה האופטימלית)
 Q^*

ROP

איך זהו הבעיה בשטח?



בניית המודל החדש

החלטנו לבנות מודל ניהול מלאי חדש שמורכב משלושת המודלים הבאים:

• **מודל למידת מכונה (Random forest) ML**

• **מודל Economic Order Quantity (EOQ)**

$$EOQ = \sqrt{\frac{2 \cdot D \cdot S}{H}} \rightarrow Q^* = \sqrt{\frac{2 \cdot (ML \text{ Demand Prediction}) \cdot S}{H}}$$

• **מודל Continuous Review (Q,R)**

$$ROP = d \cdot L + z \cdot \sigma_{dL}$$

$$ROP = (ML \text{ Avg Daily Demand Prediction}) \cdot (ML \text{ Avg Lead Time Prediction}) + z \cdot (ML \text{ Prediction of } \sigma_{dL})$$

תוצאות ומסקנות

- ✓ המודל עזר לחזות את הביקוש בצורה טובה: התחזיות היו מדויקות יותר מאשר שיטות קודמות.
- ✓ סופי שבוע משפיעים מאוד על הקניות: כשהוספנו את זה, התחזיות השתפרו בצורה ברורה.
- ✓ המערכת החדשה פשוטה אבל חכמה: עבודה עם Excel קלה לתפעול – ועדיין חזקה מאוד.
- ✓ הגרסה השנייה הרבה יותר מוצלחת מהראשונה: עשינו שיפור גדול במדדים ובתוצאות בשטח.
- ✓ אפשר להשתמש במודל גם במחלקות נוספות: אפשר להרחיב אותו לכל החנות בעתיד בלי בעיה.

